

ЛАБОРАТОРНАЯ РАБОТА № 5

Решение задач многоэкстремальной оптимизации

Методические указания.

1. Случайный мултистарт

Цель работы:

1. Изучение методов решения задач многоэкстремальной оптимизации.
2. Разработка программ реализации алгоритмов мултистарта (метода ближайшего соседа, метода конкурирующих точек).
3. Решение задачи многоэкстремальной оптимизации для функции Шекеля.

Постановка задачи

Найти минимумы функции Шекеля (глобальный минимум, в частном случае):

$$f(x) = -\sum_{i=1}^3 \frac{a}{f_i^0 + b \sum_{j=1}^3 (x_j - x_{ij}^0)^2}, \quad \sum_{i=1}^3 \frac{1}{f_i^0} = f^0, \quad (1)$$
$$f^0 = -c, \quad x_{ij}^0 \in D \subset [\alpha, \beta]^3, \quad i, j = 1, 2, 3.$$

Стратегия поиска

Стратегия метода случайного мултистарта состоит в многократном решении задачи локального поиска экстремума из случайных начальных точек. Случайный мултистарт является наиболее известным и широко используемым представителем семейства методов мултистарта. В чистом виде случайный мултистарт является неэффективным алгоритмом, поскольку при его использовании большое количество ненужной вычислительной работы затрачивается на повторные спуски к точкам локальных минимумов. Однако его модификации, называемые методами конкурирующих точек и основанные на использовании процедур кластеризации для предотвращения повторных спусков, являются одними из наиболее эффективных алгоритмов.

Основная сложность при практической реализации метода мултистарта состоит в следующем. Для того чтобы с высокой надежностью отыскать точку глобального минимума, необходимо начальных точек для локальных алгоритмов взять существенно больше, чем число локальных минимумов функции $f(x)$, (которое к тому же обычно неизвестно). Но при этом большая часть вычислительных затрат будет связана с нахождением точек локальных минимумов, обнаруженных ранее. Для преодоления этой сложности мултистарт обычно модифицируют одним из следующих способов, основанных на эвристических предположениях о том, что точки локальных минимумов находятся достаточно далеко друг от друга.

Первый способ состоит в том, что найденные точки локальных минимумов окружаются некоторыми окрестностями и попадание других точек в эти окрестности считаются равносильными попаданию в точки локальных минимумов. Корректное использование получающегося метода возможно лишь в тех случаях, когда можно точно указать размер и форму соответствующих окрестностей, либо целиком лежащих внутри области притяжения точек локальных минимумов, либо гарантированно не содержащих точек локального минимума.

Второй способ, называемый иногда методом *конкурирующих точек*, состоит в том, что поиск локальных экстремумов производится одновременно (параллельно), причем точки, расстояние между которыми не превышает некоторого фиксированного, достаточно малого числа, объединяются, т.е. заменяются одной из них – той, значение функции в которой меньше. В качестве начальных точек для локального поиска обычно выбирают точки какой-либо из равномерных на X сеток. Наибольшей популярностью пользуются случайные сетки и $\Pi\tau$ -сетки. Число начальных точек должно существенно превышать ожидаемое число локальных минимумов целевой функции. Проблема объединения точек является проблемой **кластерного анализа**, и поэтому любой метод кластерного анализа может быть использован в указанных целях. Одним из наиболее простых и популярных является метод *ближайшего соседа*, основанный на предположении, что расстояние $\rho_{ij} = \rho(z_i, z_j)$ в некоторой метрике ρ между точками z_i и z_j , принадлежащими окрестности одного локального минимума, меньше расстояний между точками, принадлежащими окрестностям разных минимумов.

Алгоритм метода ближайшего соседа

Ш.1. Генерируются K точек $(z_1, z_2, \dots, z_K)$ случайным образом с помощью, например, алгоритма Монте-Карло. Считается, что все они принадлежат различным кластерам (кластер ассоциируется с окрестностью локального минимума).

Ш.2. Находится ближайшая пара точек z_i, z_j , т.е. такая пара, для которой $\rho_{ij} = \arg \min_{k,l=1,\dots,K} \rho_{kl}$.

Ш.3. Если расстояние $\rho_{ij} = \rho(z_i, z_j)$ между ближайшими соседями не превосходит некоторое достаточно малое число $\delta > 0$, то точки z_i и z_j , а также соответствующие им кластеры объединяются и число кластеров K уменьшается на единицу. После этого происходит переход на Ш.2.

Ш.4. Остановка алгоритма происходит, либо если расстояние между ближайшими соседями превосходит δ либо если остается лишь один кластер.

В качестве метрики $\rho(z_i, z_j)$ обычно выбирается евклидова метрика. Качество алгоритма как процедуры кластеризации существенно зависит от того, насколько удачно выбрано число δ . Это число должно быть достаточно малым, во всяком случае меньше расстояний между соседними точками локальных минимумов.

Алгоритм метода конкурирующих точек

Ш.1. Моделируется равномерное на X распределение. В результате получается N точек $\{x_1, x_2, \dots, x_N\}$.

Ш.2. Используя точки $\{x_1, x_2, \dots, x_N\}$ в качестве начальных, проводится одна или несколько итераций какого-либо алгоритма локальной оптимизации. Получаем точки $z_1, \dots, z_N$.

Ш.3. Применяется какой-либо метод кластеризации к точкам $z_1, \dots, z_N$. Пусть m - число получившихся кластеров. Если $m = 1$, то переход на Ш.5. Иначе переход на Ш.4.

Ш.4. Выбираются представители $x_1, x_2, \dots, x_m$ от всех кластеров (естественно выбирать в кластерах с наименьшим значением целевой функции). Положим $N = m$ и переход на Ш.2.

Ш.5. Считаем, что находимся в окрестности точки глобального минимума. Выбрать представителя от единственного кластера. Используя его в качестве начальной точки для алгоритма локальной оптимизации, обладающего высокой скоростью сходимости в окрестности точки экстремума.

Задание

Требуется найти глобальный минимум функции Шекеля.

Варианты задания:

$$1. \alpha = 0, \beta = 5. \begin{cases} a = 2, \\ b = 3, \\ c = 1. \end{cases}$$

$$2. \alpha = 2, \beta = 8. \begin{cases} a = 1, \\ b = 3, \\ c = 2. \end{cases}$$

$$3. \alpha = 3, \beta = 11. \begin{cases} a = 1, \\ b = 4, \\ c = 2. \end{cases}$$

$$4. \alpha = 1, \beta = 7. \begin{cases} a = 3, \\ b = 3, \\ c = 3. \end{cases}$$

$$5. \alpha = 1, \beta = 6. \begin{cases} a = 2, \\ b = 2, \\ c = 1. \end{cases}$$

$$6. \alpha = 0, \beta = 8. \begin{cases} a = 1, \\ b = 1, \\ c = 2. \end{cases}$$

$$7. \alpha = 2, \beta = 9. \begin{cases} a = 1, \\ b = 3, \\ c = 2. \end{cases}$$

$$8. \alpha = 0, \beta = 5. \begin{cases} a = 2, \\ b = 3, \\ c = 1. \end{cases}$$

1. Реализовать алгоритмы многоэкстремальной оптимизации методом мултистарта на одном из языков высокого уровня (C++, C#, Python, Haskell и др.).
2. Решить задачу многоэкстремальной оптимизации с помощью метода мултистарта.

2. Генетический алгоритм.

Цель работы:

1. Изучение методов решения задач многоэкстремальной оптимизации на основе генетического алгоритма.
2. Разработка программы реализации генетического алгоритма.
3. Решение задачи многоэкстремальной оптимизации для заданных многоэкстремальных функций.

Постановка задачи

Дана целевая функция $f(x) = f(x_1, x_2, \dots, x_n)$, определенная на множестве допустимых решений $D \subseteq R^n$. Требуется найти глобальные минимумы заданных функций $f(x)$ на допустимом множестве D . То есть такую точку

$$x^e = \underset{x \in D}{\operatorname{Arg\,min}} f(x), \text{ где } x = (x_1, \dots, x_n)^T, D = \{x | x_i \in [\alpha, \beta], i = 1, \dots, n\}. \quad (2)$$

Задача поиска максимума целевой функции $f(X)$ сводится к задаче поиска минимума путем замены знака перед функцией на противоположный:

$$f(x^e) = \max_{x \in D} f(x) = -\min_{x \in D} [-f(x)].$$

Стратегия поиска

Генетические алгоритмы имитируют природные способы оптимизации, присущие процессам эволюции живых систем. А именно:

- генетическое наследование;
- изменчивость;
- естественный отбор.

Целевая функция $f(x)$ соответствует природному понятию *приспособленности* живого организма. Вектор переменных $x = (x_1, \dots, x_n)^T$ целевой функции называется **фенотипом**, а отдельные его параметры – **признаками** $i = 1, 2, \dots, n$.

Любой живой организм может быть представлен своим генотипом и фенотипом.

Генотип – это совокупность наследственных признаков, информация о которых заключена в хромосомном наборе генов.

Фенотип – совокупность всех признаков и свойств организма, формирующихся в процессе взаимодействия его генотипа и внешней среды. Каждый ген имеет своё отражение в фенотипе.

Генетические алгоритмы ведут поиск решения на уровне генотипа. Каждую координату x_i вектора $x = (x_1, \dots, x_n)^T \in D$ представляют в некоторой форме s_i , удобной для использования в генетическом алгоритме и называется *геном*. Для этого необходимо выполнить преобразование, в общем случае не взаимно однозначное, вектора переменных $x = (x_1, \dots, x_n)^T \in D$ в некоторую структуру $s = (s_1, s_2, \dots, s_n)^T \in S$, называемую **хромосомой**

(**генотипом, особью**): $D \xrightarrow{e} S$, где e функция кодирования, S - пространство представлений (как правило $D \neq S$).

Для того, чтобы восстанавливать по хромосоме решение, необходимо задать обратное преобразование $S \xrightarrow{e^{-1}} D$, где e^{-1} - функция декодирования.

В пространстве представлений S вводится так называемая **функция приспособленности (функция фитнеса)** $\mu(s): S \xrightarrow{\mu} R$, где R - множество вещественных чисел, аналогичная целевой функции $f(x)$ на множестве D . Функция $\mu(s)$ может быть любая функция, удовлетворяющая условию:

$$\forall x^1, x^2 \in D: s^1 = e(x^1), s^2 = e(x^2), s^1 \neq s^2, \text{ еслу } f(x^1) > f(x^2), \text{ то } \mu(s^1) > \mu(s^2).$$

При решении используются конечные наборы:

$$I = \{s^k = (s_1^k, s_2^k, \dots, s_n^k)^T, k = 1, 2, \dots, m\} \subset S$$

Возможных решений, называемых **популяциями**, где s^k - хромосомы с номером k , m - размер популяции, s_i^k - ген с номером i k - той популяции.

Затем осуществляется обратное преобразование:

$$x^e = e^{-1}(s^*).$$

Различают два способа кодирования:

1. Бинарное кодирование.
2. Вещественное кодирование.

Будем использовать второй вариант кодирования. В этом случае целевая функция может использоваться непосредственно как функция фитнеса. Тогда в качестве функции фитнеса $\mu(x)$ получается как преобразование целевой функции, т.е. *функция фитнеса* $\mu(x): D \xrightarrow{\mu} R$, где R - множество вещественных чисел, аналогична целевой функции $f(x)$.

Функцией $\mu(x)$ может быть любая функция, удовлетворяющая следующему условию:

$$\forall x^1, x^2 \in D: x^1 \neq x^2, \text{ если } f(x^1) > f(x^2), \text{ то } \mu(x^1) > \mu(x^2).$$

Решение исходной оптимизационной задачи $f(x^*) = \min_{x \in D} f(x)$ сводится к поиску решения x_μ^* другой оптимизационной задачи:

$$\mu(x_\mu^*) = \max_{x \in D} \mu(x). \quad (3)$$

В силу выбора функции $\mu(x)$, решение задач (1) и (2) (хромосома) совпадают:

$$x^e = x^* = \text{Arg min}_{x \in D} f(x) = \text{Arg max}_{x \in D} \mu(x) = x_\mu^*. \quad (4)$$

При решении задачи (2) используются конечные наборы $I = \{x^k = (x_1^k, \dots, x_n^k)^T, k = 1, 2, \dots, Mp\} \subset D$ возможных решений, называемых *популяциями*, где x^k - хромосома с номером k , M - размер популяции, x_i^k - ген с номером i .

Генетический алгоритм.

III.1. Формирование исходной популяции.

III.1.1. Задается номер популяции $t = 0$, максимальное количество популяций Np , номер итерации цикла $k = 1$, размер популяции Mp .

III.1.2. Случайным образом выбирается начальная точка x^0 - исходная хромосома. Она может быть выбрана как внутренняя точка гиперкуба области допустимых значений D . Из этой точки формируется исходная популяция. Для этого с помощью равномерного распределения на единичном отрезке $[0,1]$ Mp раз генерируется последовательность из n случайных точек $\{P_i^{0k}\}_{i=1,n}^{k=1,Mp}$, $i = 1, \dots, n$; $k = 1, \dots, Mp$. Используя линейное преобразование, каждая точка отображается на соответствующий ей промежуток $[\alpha, \beta]$: $P_i^k = (\beta_i - \alpha_i)P_i^{0k} + \alpha_i$. Составляя векторы из точек последовательности $\{P_i^k\}$ при фиксированных k , получаем Mp начальных векторов $x^k = (x_1^k, \dots, x_n^k)^T$, $x_i^k = P_i^k$, $i = 1, \dots, n$, координаты которых x_i имеют равномерное распределение на отрезках $[\alpha_i, \beta_i]$, $i = 1, \dots, n$. Таким образом, может быть сформирована начальная популяция $I_0 = \{x^k, k = 1, \dots, Mp \mid x^k = (x_1^k, x_2^k, \dots, x_n^k) \in D\}$.

III.1.3. Вычисляется значение функции фитнеса для каждой особи

$$x^k \in I_0: \mu_k = \mu(x^k), k = 1, \dots, Mp \text{ и популяции } I_0 \text{ в целом } \mu = \sum_{k=1}^{Mp} \mu_i.$$

III.2. Отбор (селекция).

Селекция – это операция, которая осуществляет отбор особей (хромосом) x^k в соответствии со значениями функции фитнеса $\mu(x^k)$ для последующего их скрещивания.

Ш.2.1. Вычислить кумулятивную вероятность $q_i = \sum_{j=1}^i \mu_j(x^j)$, $i = 1, 2, \dots, Mp$.

Ш.2.2. Сформировать случайное действительное число r в интервале $(0, Mp]$.

Ш.2.3. Выбрать i -ю хромосому x^i ($1 \leq i \leq Mp$) так, чтобы $q_{i-1} < r \leq q_i$.

Ш.2.4. Перейти на Ш.2.2. до тех пор, пока не будет сформирована новая популяция ($while(i \leq Mp)$).

Ш.3. Кроссинговер (скрещивание).

Скрещивание – это операция, при которой из нескольких, обычно двух хромосом (особей), называемых родителями, порождается одна или несколько новых, называемых потомками.

Ш.3.1. Определяется параметр $Pc \in (0, 1]$ как вероятность кроссинговера. Эта вероятность дает ожидаемое число $Pc \cdot Mp$ хромосом, подвергаемых операции кроссинговера.

Ш.3.2. Для операции кроссинговера выполняется процесс, повторяющийся от $i = 1$ до $Pc \cdot Mp$: формируется случайное действительное число r из сегмента $[0, 1]$, при этом, если $r < Pc$, то хромосома x^i выбирается как родительская.

Ш.3.3. Отбираются пары родительских хромосом (x^i, x^j) , где $i \neq j$. Действие оператора кроссинговера осуществляется следующим образом:

Ш.3.4. Формируется случайное число $c \in (0, 1)$, затем оператор кроссинговера, действующий на исходные пары (x^i, x^j) , производит две хромосомы потомки X и Y :

$$X = c \cdot x^i + (1 - c) \cdot x^j, \quad Y = (1 - c) \cdot x^i + c \cdot x^j.$$

Ш.3.5. Если допустимое множество является выпуклым, то кроссинговер обеспечивает допустимость обоих потомков, в случае если допустимы оба родителя. Следует проверить допустимость каждого потомка перед тем, как он будет включен в новую популяцию. Если оба потомка являются допустимыми, тогда родители заменяются этими потомками. Если это не так, сохраняется допустимый потомок, если он существует, а затем вновь выполняется оператор кроссинговера с новым значением случайного числа c до тех пор, пока не будут получены два новых допустимых потомка или не будет превышено заданное число циклов. В этом случае осуществляется замена родителей только теми (сохраненными ранее) потомками, которые оказались допустимыми.

Ш.4. Мутация.

Мутация – это преобразование хромосомы, случайно изменяющее один или несколько из её генов. Оператор мутации предназначен для того, чтобы поддерживать разнообразие особей в популяции.

Ш.4.1. Определим параметр $Pm \in (0, 1]$ как вероятность мутации. Эта вероятность дает ожидаемое число $Pm \cdot Mp$ хромосом, подвергаемых операции мутации.

Ш.4.2. Для операции мутации выполняется процесс, повторяющийся от $i = 1$ до $Pm \cdot Mp$: формируется случайное действительное число r из сегмента $[0, 1]$, при этом, если $r < Pm$, то хромосома x^i выбирается как родительская для операции мутации. Для каждой выбранной родительской хромосомы x^i , обозначенной как $Z = (x_1, x_2, \dots, x_n)$, производится мутация.

Ш.4.3. Поочередно рассматривается каждый потомок из ожидаемого числа $Pm \cdot Mp$ хромосом. Среди генов выбранной родительской хромосомы $Z = (x_1, x_2, \dots, x_n)$ случайно (с вероятностью $1/n$) выбирается один с номером $p \in (1, 2, \dots, n)$ подлежащий замене. Его новое

значение x_p^M случайным образом выбирается из промежутка $[\alpha_p, \beta_p]$ изменения выбранной координаты x_p .

Ш.5. Формирование новой популяции.

Ш.5.1. С равной вероятностью из потомков мутантов предыдущего шага выбирается один $x^M = (x_1, x_2, \dots, x_p^M, \dots, x_n)$.

Ш.5.2. Выбранный потомок добавляется в популяцию вместо хромосомы, которой соответствует наименьшее значение функции фитнеса (наихудшее из допустимых значений).

Ш.5.3 Вычисляется значение функции фитнеса для мутантного потомка $\mu_M = \mu(x^M)$.

Ш.5.4. Проверка условий:

Ш.5.4.1. Если $k < Mp$, то $k = k + 1$ и переход на Ш.2.

Ш.5.4.2. Если $k = Mp$, то $t = t + 1$ и переход на Ш.6.

Ш.6. Проверка условия останова генетического алгоритма.

Условием окончания работы генетического алгоритма является формирование заданного количества популяций $t = Nr$.

Ш.6.1. Если условие не выполнено, то полагаем $k = 1$ и переход на Ш.2.

Ш.6.2. Если условие окончания работы выполнено, то в качестве решения (приближенного) задачи $\mu(x_\mu^*) = \max_{x \in D} \mu(x)$ выбирается особь с лучшим значением функции фитнеса из текущей популяции: $x_\mu^* \cong x_\mu^e = \text{Arg max } \mu(x^k)$, а по нему определяется приближенное решение поставленной задачи $f(x^*) = \min f(x) : x^* = x_\mu^*$.

Замечание 1. В качестве функции фитнеса можно использовать обратную целевую функцию $\mu(x) = \frac{1}{f(x)}$.

Замечание 2. Обычно размер популяции выбирают в пределах 30-60 особей.

Замечание 3. Вероятность кроссинговера принимается равной $Pc = 0.3 - 0.5$, вероятность мутации $Pm = 0.05 - 0.2$.

Варианты задания:

1. $f_1(x) = -\sum_{i=1}^{30} x_i \sin(\sqrt{|x_i|}), n = 30, \alpha = -2, \beta = 4;$
2. $f_2(x) = \left(\frac{1}{200} + \sum_{j=1}^{10} \frac{1}{j + \sum_{i=1}^2 (x_i - a_{ij})^4} \right)^{-1}, n = 2, a_{ij} = i + j, \alpha = 0, \beta = 5;$
3. $f_3(x) = \sum_{i=1}^{11} \left[a_i - \frac{x_1(b_i^2 + b_i x_2)}{b_i^2 + b_i x_3 + x_4} \right]^2, n = 4, a_i = 2i, b_i = a_i^n, \alpha = -1, \beta = 10;$
4. $f_4(x) = 4x_1 + 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 3x_2^4, n = 2, \alpha = 2, \beta = 15;$
5. $f_5(x) = \left(x_2 - \frac{5.1}{4\pi^2} x_1^2 + \frac{5}{\pi} x_1 - 6 \right) + 10 \left(1 - \frac{1}{8\pi} \right) \cos x_1 + 10, n = 2, \alpha = 1, \beta = 14;$
6. $f_6(x) = \sum_{i=1}^n [x_i^2 - 10 \cos(2\pi x_i) + 10], n = 3, \alpha = 0, \beta = 20;$
7. $f_7(x) = -20 \exp \left(-0.2 \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \right) - \exp \left(\frac{1}{n} \sum_{i=1}^n \cos(2\pi x_i) \right) + 20, n = 3, \alpha = 0.5, \beta = 12;$
8. $f_8(x) = \frac{1}{200} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos \left(\frac{x_i}{\sqrt{i}} \right) + 1, n = 4, \alpha = 0.8, \beta = 20;$

1. Реализовать генетический алгоритм многоэкстремальной оптимизации на одном из языков высокого уровня (C++, C#, Python, Haskell и др.).
2. Решить задачу многоэкстремальной оптимизации с помощью генетического алгоритма.

Требования к отчету.

1. Отчет должен содержать:
 - 1.1. титульный лист;
 - 1.2. цель работы;
 - 1.3. постановку задачи;
 - 1.4. проверку решения на допустимость.
2. Исследование выполнить с помощью написанной Вами программы с результатами в виде таблицы.
3. Кроме текста исследования следует привести также текст исходного кода программ.
4. Отчет оформляется в формате PDF желательно в редакторе TEX.