

Лекция № 2

Ю.Т. Каганов, к.т.н., доцент, Кафедра ИУ-5

Методы математического программирования

Алгоритм и сходимость алгоритмов.

Понятие алгоритма. Алгоритмические отображения.

Определение. Алгоритмом называется итеративный процесс вычислений, который порождает последовательность точек в соответствии с предписанным набором правил, включающим критерий окончания этого процесса.

Алгоритмическое отображение.

Пусть $A: X \rightarrow X; X \subset E^n, x^{(k+1)} = A(x^{(k)})$ для $\forall k \in \mathbb{N}$,

Таким образом $x^{(k+1)} = A(A(\dots(A(x^{(0)}))\dots))$, где $x^{(0)}$ - начальная точка.


В качестве реализации алгоритмического отображения методов оптимизации может быть выбрана некоторая функция спуска, зависящая от переменных проектирования $\varphi(x^{(k)})$.

При этом она должна удовлетворить условию $\varphi(x^{(k+1)}) \leq \varphi(x^{(k)})$.

В качестве функции спуска может быть использована целевая функция $f(x)$ или градиент целевой функции $\nabla f(x)$.

Алгоритм и сходимость алгоритмов.

Композиция алгоритмических отображений.



1. Выбор направления уменьшения функции спуска d – в области возможного направления. Например

$$\nabla f(x) * d < 0$$

Этот алгоритм обозначим D ($d \in E^n$)

2. Выбор шага $\alpha \rightarrow (\varphi(x^{(k)} + \alpha^{(k)} * d^{(k)}) \leq \varphi(x^{(k)}))$
 $\alpha^{(k)e} = Arg \min \varphi(x^{(k)} + \alpha^{(k)} * d^{(k)})$

Этот алгоритм обозначим U .

3. Если решается задача с ограничениями, то необходимо ввести еще один алгоритм L , учитывающий наличие ограничений.


Тогда общий алгоритм будет композицией алгоритмов: $A(\varphi(x)) = L * U * D(\varphi(x))$

Алгоритм и сходимость алгоритмов.

Критерий окончания процесса оптимизации.

Точка зрения математика состоит в нахождении точного решения x^e .

Точка зрения инженера состоит в определении области $\Omega_\varepsilon \subset X$ близкой к оптимальной. В связи с этим существует несколько критериев останова в зависимости от точности решаемой задачи.



Точка зрения инженера.

Критерии останова алгоритма.

1. $\|x^{(k+N)} - x^{(k)}\| < \delta$
2. $\frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k)}\|} < \delta$
3. $|\varphi(x^{(k)}) - \varphi(x^{(k+N)})| < \varepsilon$
4. $\frac{\varphi(x^{(k)}) - \varphi(x^{(k+1)})}{\varphi(x^{(k)})} < \varepsilon$

Алгоритм и сходимость алгоритмов.

Скорость сходимости алгоритмов.

Пусть $\{x^{(k)}\}$ сходится к x^e , тогда, если выполняются неравенства:

$$(1.) \frac{\lim}{k \rightarrow \infty} \sup \frac{\|x^{(k+1)} - \bar{x}\|}{\|x^{(k)} - \bar{x}\|} = \beta, \quad \beta < 1, \quad \beta - \text{коэффициент сходимости,}$$

$\gamma = 1$ - **линейная сходимость**,

$$(2.) \frac{\lim}{k \rightarrow \infty} \sup \frac{\|x^{(k+1)} - \bar{x}\|}{\|x^{(k)} - \bar{x}\|^\gamma} < \beta < +\infty, \quad \gamma > 1, \quad \gamma - \text{порядок сходимости,}$$

$\gamma > 2$ — **суперлинейная сходимость**.

При $\gamma = 2$ — **квадратичная сходимость**.

Стратегия методов спуска.

Методы математического программирования основаны на использовании итерационных алгоритмов поиска значений переменных проектирования x^e , отвечающих экстремуму целевой функции при заданных ограничениях. При этом строится алгоритмическое отображение над функцией спуска $\varphi(x)$, включающей как целевую функцию $f(x)$, так и функции ограничений $g(x)$.

Задачи выпуклого программирования

Формулировка задачи

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$,

$g: X \rightarrow Z; X \subset E^n, Z \subset E^m$,

$f(x) \in C^1(X), g(x) \in C^1(X)$,

$x^e = \operatorname{Arg} \min f(x), x_i \geq 0, i = 1..n$


$g_j(x) = 0, j = 1..\ell$ – ограничения типа равенств.

$g_j(x) \leq 0, k = (\ell + 1)..m$ – ограничения типа неравенств.

Обозначим множество индексов: $K = \{l + 1, m\}, k \in K$.

Задачи выпуклого программирования

Активные ограничения.



В процессе решения задачи происходит перемещение текущей точки из заданной начальной точки в конечную точку. При этом возможен выход на границу области допустимых решений X . Такие нарушенные ограничения носят название активных.

Определение множества индексов активных ограничений:

$$K_A = \left\{ k \in K \mid (\forall g_k(x) \leq 0) \wedge (\exists g_{k_A}(x) = 0) \Rightarrow k_A \in K_A \subset K \right\}$$


Функция Куна-Таккера (функция Лагранжа) для задач выпуклого программирования (1951г.).

$$L(x, \lambda, \mu) = f(x) + \sum_{j=1}^l \lambda_j g_j(x) + \sum_{k=l+1}^m \mu_k g_k(x)$$

Продифференцируем функцию $L(x, \lambda, \mu)$ по x и приравняем 0.

Если продифференцировать по μ_k , то получим неравенства $g_k(x) \leq 0$, что не позволяет получить единственное решение. Противоречие состоит в том, что для ЗВП имеется единственное решение.

$$\left. \frac{\partial L(x, \lambda, \mu)}{\partial x_i} \right|_{x^e} = 0 \Rightarrow \nabla_x f(x^e) = -\sum_{j=1}^l \lambda_j \nabla g_j(x) - \sum_{k=l+1}^m \mu_k \nabla g_k(x)$$



Лемма: Градиент целевой функции $\nabla f(x^e)$ равен линейной комбинации градиентов функций ограничений в точке условного экстремума x^e : $-\nabla f(x^e) = \sum_{j=1}^l \lambda_j \nabla g_j(x^e) + \sum_{k=l+1}^m \mu_k \nabla g_k(x^e)$

Множество всех векторов

называется множеством **возможных направлений**.

Теорема Каруша-Куна-Таккера.

Рассмотрим задачу выпуклого программирования

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1; f(x) \in C^1(X)$

$g: X \rightarrow Z; X \subset E^n, Z \subset E^m; g(x) \in C^1(X)$

Требуется найти: $x^e = \text{Arg min } f(x), x \in X$

$x_i \geq 0, i = 1..n$,

$g_j(x) = 0, j = 1..l$,

$g_k(x) \leq 0, k = l + 1..m.$ Для этого решение ЗВП должно удовлетворять следующим условиям:

$x^e \in X,$

$\mu_k g_k(x^e) = 0, \lambda_j g_j(x^e) = 0.$

$\nabla_x f(x^e) + \sum_{j=1}^l \lambda_j \nabla g_j(x^e) + \sum_{k=l+1}^m \mu_k \nabla g_k(x^e) = 0$.

$\mu_k \begin{cases} = 0, g_k(x) < 0, \\ > 0, g_{kA}(x) = 0. \end{cases}$

Если эти условия выполнены, то

x^e – решение ЗВП.

Условия:

- называются **условиями дополняющей нежесткости.**

Теория двойственности

Седловая точка функции Лагранжа. Двойственность.

Рассмотрим упрощенную задачу выпуклого программирования.

Пусть заданы условия на $f(x)$ и $g(x)$ как и ранее.

$$\begin{cases} x^e = \text{Arg min } f(x), \\ x_i \geq 0, i = 1..n, \\ g_j(x) \leq 0, j = 1..m. \end{cases}$$

Тогда функция Лагранжа может быть записана:


$$L(x, \mu) = f(x) + \sum_{j=1}^m \mu_j g_j(x).$$

Рассмотрим случай, когда $x = x^e, \mu = \mu^e$:

$$L(x, \mu^e) \geq L(x^e, \mu^e) \geq L(x^e, \mu).$$

Таким образом седловая точка функции Лагранжа (функции Куна-Таккера) является $[x^e, \mu^e]^T$.

Именно эта точка является решением ЗВП.



Постановка задачи многомерной оптимизации

Рассмотрим задачи нелинейной оптимизации в общем случае.

Пусть $x = (x^{(1)}, \dots, x^{(n)})^T \in R^n$, S – некоторое множество из пространства R^n . Пусть $f_0(x), \dots, f_m(x): S \rightarrow R^1$. Тогда задачу минимизации можно рассматривать в следующем виде

$$\min f_0(x) \text{ при } f_j(x) \leq 0, j = 1, \dots, m, x \in S. \quad (1)$$

$f_0(x)$ - будем называть *целевой функцией*. Функции $f_j(x) \leq 0$, как было принято нами ранее, обозначим $g_j(x) \leq 0$ или $g_j(x) = 0$.

Они называются *функциями ограничений* и зависят от типа ограничений – равенств или неравенств. Множество S – называется *базовым допустимым множеством*, а множество Q

$Q = (x \in S | g_j(x) \leq 0, j=1, \dots, m)$. Называется просто *допустимым множеством*.

Классификация типов задач многомерной ОПТИМИЗАЦИИ

- *Задачи на условный экстремум:* $Q \subset R^n$.
- *Задачи на безусловный экстремум:* $Q \equiv R^n$.
- *Гладкие задачи:* $\forall f_j(x) \in C^k(Q), j = 0, \dots, m$.
- *Негладкие задачи:* $\exists f_j(x) \notin C^k(Q), j = 0, \dots, m; \forall k \geq 1$.
- *Задачи с линейными ограничениями:* все функциональные ограничения являются *линейными функциями*:

$$f_j(x) = \sum_{i=1}^n a_j^i x^i + b_j, j = 1, \dots, m. \text{ При этом}$$

*базовое множество S является многогранником. Если $f_0(x)$ также линейная функция, то исходная задача (1) называется **задачей линейной оптимизации**.*

Классификация типов задач многомерной оптимизации

1. Свойства допустимых множеств.

- Задача (1) называется *допустимой*, если $Q \neq \emptyset$.
- Задача (1) называется *строго допустимой*, если существует такой вектор $x \in \text{int}Q$, что $f_j(x) < 0$ (или > 0) для всех ограничений-неравенств и $f_j(x) = 0$ для всех ограничений-равенств (условие Слэйтера).

2. Типы решений задачи (1).

- Точка x^* называется оптимальным глобальным решением задачи (1), если $f_0(x^*) \leq f_0(x)$ для всех $x \in Q$ (*глобальный минимум*). В этом случае $f_0(x^*)$ называется (*глобальным*) оптимальным значением задачи.
- точка x^* называется *локальным решением задачи (1)*, если для всех $x \in \bar{Q} \subset Q$ выполнено неравенство $f_0(x^*) \leq f_0(x)$ (*локальный минимум*).

Стратегия методов спуска.

ЗВП

$$\begin{cases} \left\{ \begin{array}{l} x^e = \text{Arg min } f(x), x \in X; \\ x_i \geq 0, i = 1, \dots, n; \\ g_j(x) \leq 0, j = 1, \dots, m. \end{array} \right. \end{cases}$$

$$x^e, \bar{x} \in \Omega_\varepsilon, \bar{x} = \lim_{k \rightarrow N} x^k$$

Выпуклая функция:

$$\varphi(x) = \varphi[f(x), g(x)]$$

$$\varphi : X \rightarrow R$$

$$X \subset E^n$$


$$\Omega_\varepsilon \subseteq U_\varepsilon(x) \subset E^n$$

Алгоритмическое отображение состоит в том, что требуется на каждой итерации производить поиск $x^{(k+1)} = A\{\varphi[f(x^{(k)}), g(x^{(k)})]\}$ так, чтобы

$$\varphi(x^{(k+1)}) \leq \varphi(x^{(k)})$$

$$\|x^e - \bar{x}\| \leq \delta \quad x^e, \bar{x} \in \Omega_\varepsilon$$

$$|f(x^e) - f(\bar{x})| \leq \varepsilon$$



Стратегия методов спуска

Стратегия ММП для ЗВП состоит в выборе $x^{(k+1)} = x^{(k)} + \Delta x^{(k)}$ таким образом, чтобы $\varphi(x^{(k)} + \Delta x^{(k)}) \leq \varphi(x^{(k)})$ для $\forall x^{(k)} \in X$

При этом для большинства методов МП $\Delta x^{(k)} = \alpha^{(k)} d^{(k)}$,



где $d^{(k)} \in E^n$ — направление поиска, $\alpha^{(k)} \in E^1$ — шаг в направлении поиска.

Решение задачи ММП состоит в следующем:

1. Выбор направления поиска на каждой итерации оптимизации $d^{(k)} \in X \subset E^n$

2. Выбор величины шага $\alpha^{*(k)} \in E^1$ таким образом, чтобы $\alpha^{*(k)} = \text{Arg min } \varphi(x^{(k)} + \alpha^{(k)} d^{(k)})$ в направлении вектора $d^{(k)} \in X \subset E^n$

Стратегия методов спуска.



Простейшие методы ММП для решения ЗВП.


Их можно разбить на 3 основных класса:

1. Методы 0-го порядка (не использующие производные).
2. Методы 1-го порядка (использующие 1-е производные).
3. Методы 2-го порядка (использующие 2-е производные).

**Рассмотрим простейшие представители каждого
из этих классов.**

Метод покоординатного спуска (метод 0-го порядка)

Функция $\varphi(x) \in C^0(X)$ – непрерывная функция.



Алгоритм:

Ш1. Направление d^k - выбирается вдоль координаты X_k от точки $x^{(k)}$, т.е.

$$d^{(k)} = \frac{x_k}{\|x_k\|} = e^k$$

Ш2. Определяется величина шага $\alpha^{*(k)} = \operatorname{Arg} \min_{\alpha \in E^1} \varphi(x^{(k)} + \alpha^{(k)} d^{(k)})$

Ш3. Формируется новое значение $x^{(k+1)} = x^{(k)} + \alpha^{*(k)} d^{(k)}$

Ш4. Проверка сходимости:

Если $(|\varphi(x^{(k+1)}) - \varphi(x^{(k)})| \leq \varepsilon, \|x^{(k+1)} - x^{(k)}\| \leq \delta)$, то *КОНЕЦ*

Иначе $k=k+1$ и переход на Ш 1.

Достоинства: возможность оптимизации для задач с недифференцируемыми функциями.

Недостатки:

1. Низкая скорость сходимости (сублинейная, т.е. $\gamma < 1$)

2. Возможность закливания при плохой обусловленности задачи, т.е. когда функция $\varphi(x)$ имеет овражный характер.

Обусловленность задачи


Определяется числом обусловленности матрицы Гессе (если она существует), т.е. отношением $\chi = \frac{L}{l}$.

Где L - максимальное собственное число $H(x^{(k)})$,

l - минимальное собственное число $H(x^{(k)})$.

В случае отсутствия матрицы Гессе числом обусловленности может быть отношение:


$$\chi = \lim_{\delta \rightarrow 0} \frac{\sup \|x^{(k)} - x^e\|^2}{\inf \|x^{(k)} - x^e\|^2}.$$



Пример: функция Розенброка :

$$f(x_1, x_2) = 100(x_2^2 - x_1)^2 + (x_2 - 1)^2 + C$$

Метод наискорейшего спуска (метод 1-го порядка)



Метод наискорейшего спуска (метод 1-го порядка).

Функция $\varphi(x) \in C^1(X)$ - класс 1 раз дифференцируемых функций.

$x^{(k+1)} = x^{(k)} + \Delta x^{(k)} = x^{(k)} + \alpha^{(k)} d^{(k)}$ – в ряд Тейлора, тогда, если учитывать
Разложим функцию $\varphi(x^{(k)} + \alpha^{(k)} d^{(k)})$ только 2 члена ряда, получим:

$$\varphi(x^{(k+1)}) = \varphi(x^{(k)}) + \nabla^T \varphi(x^{(k)}) \Delta x^{(k)} + o(\|\Delta x^{(k)}\|)$$

Для того, чтобы функция уменьшалась, необходимо, чтобы $d^{(k)} \sim -\nabla \varphi(x^{(k)})$
 $d^{(k)} = -\frac{\nabla \varphi(x^{(k)})}{\|\nabla \varphi(x^{(k)})\|}$. Тогда $x^{(k+1)} = x^{(k)} - \frac{\nabla \varphi(x^{(k)})}{\|\nabla \varphi(x^{(k)})\|} \alpha^{*(k)}$

При этом $\alpha^{*(k)} = \text{Arg min}_{\alpha \in E^1} \varphi(x^{(k)} + \alpha^{*(k)} d^{(k)})$

Особенность МНС: $\nabla^T \varphi(x^{(k+1)}) \nabla \varphi(x^{(k)}) = 0$; то есть $d^{(k+1)T} d^{(k)} = 0$.

Достоинства. Линейная скорость сходимости для функций $\varphi(x)$ близких к квадратичным.

Недостатки:

1. Функция $\varphi(x) \in C^1(X)$ – должна быть дифференцируема.
2. Возможность закливания при плохой обусловленности задачи.

Метод Ньютона (метод второго порядка)

Условием использования этого метода является: $\varphi(x) \in C^2(X)$,

а также условие выпуклости $\varphi(x)$ в окрестности точки поиска.

Точка x^* — стационарная точка (точка локального экстремума) .

Пусть: $\varphi(x^*) = \min(\varphi(x))$ Тогда :

$$\bar{x} \in U_\varepsilon(x^*) \quad \varphi(x^*) = \varphi(\bar{x} + \Delta x) = \varphi(\bar{x}) + \nabla^T \varphi(x) \Delta x^* + \frac{1}{2} \Delta x^T H(\bar{x}) \Delta x + o(\|\Delta x\|^2)$$




$$x^* = \bar{x} + \Delta x \quad \text{где} \quad H(\bar{x}) = \left\{ \frac{\partial^2 \varphi(\bar{x})}{\partial x_i \partial x_j} \right\}_{i=1..n, j=1..n}$$

Разложение функции $\varphi(x^*)$ в окрестности x^* в ряд Тейлора до 3-го члена дает квадратичную аппроксимацию этой функции в $U_\varepsilon(x^*)$:

$$O = \nabla \varphi(\bar{x}) + H^T(\bar{x})(x^* - \bar{x}) \quad . \quad x^{(k+1)} = x^{(k)} - H^{-1}(x^{(k)}) \nabla \varphi(x^{(k)}) .$$

$$d^{(k)} = -H^{-1}(x^{(k)}) \nabla \varphi(x^{(k)}) ; \quad \alpha^{*(k)} = \text{Arg min } \varphi_d(\alpha^{(k)}) ; \quad x^{(k+1)} = x^{(k)} + \alpha^{*(k)} d^{(k)} .$$

Метод Ньютона (метод второго порядка)



Метод Ньютона (метод второго порядка)

Сопряженность:

$$d^{(k+1)} H^{-1}(x^{(k)}) d^{(k)} = 0$$

Достоинства :

Для функций, близких к квадратичным, скорость сходимости алгоритма суперлинейная.


Недостатки:

- 1.Необходимость вычисления $H^{-1}(x^{(k)})$.
- 2.Процесс решения сильно зависит от выбора $x^{(0)}$ (т.е. от начальной точки) .
- 3.Функция $\varphi(x)$ должна быть выпуклой во всех точках $x^{(k)}$, то есть $H(x^k) > 0$.

Эффективность численных методов

Эффективность численных методов.

$\mathcal{F}$ — класс задач = $(\Sigma, O, \mathcal{F}_\varepsilon)$



Утверждение. Не существует универсальных методов решения задач оптимизации, другими словами, невозможно определить наилучший метод решения задач P . Возможно, определить класс методов для заданного класса задач. Класс задач — F , $P \in \mathcal{F}$, где $\mathcal{F}$ — выделенный класс задач.

Замечание. Как правило используемые методы разбиваются для решения многих однотипных задач с близкими характеристиками.

Утверждение. В силу разбиения эффективности метода M на всем классе F можно считать естественной характеристикой его качества.

Утверждение. Метод μ не имеет полной информации о решаемой задаче P .

Теорема о бесплатных завтраках. (Девид Волперт и Уильям Макриди, NFL, 1997) Если алгоритм хорошо работает над определенном классом задач, то он обязательно платит за это снижением производительности на множестве всех оставшихся задач.

Эффективность численных методов оптимизации

Естественно определить эффективность метода $\mathcal{M}$ на паре $(\Sigma, \mathcal{O})$ как его эффективность на наихудшем представителе $\mathcal{P}_w$ из $(\Sigma, \mathcal{O})$. Заметим, что задача $\mathcal{P}_w$ может быть трудной только для этого конкретного метода $\mathcal{M}$

Эффективность метода $\mathcal{M}$ на задаче $\mathcal{P}$ определяется через общие вычислительные затраты метода $\mathcal{M}$, необходимые для того, чтобы решить задачу $\mathcal{P}$.

Решить задачу $\mathcal{P}$ означает найти ее приближенное решение с заранее заданной точностью $\varepsilon > 0$.

Введем обозначение $\mathcal{T}_\varepsilon$ для некоторого критерия остановки, способного оценить качество предлагаемого решения.

Эффективность численных методов ОПТИМИЗАЦИИ

Формальное определение класса решаемых задач

$$\mathcal{F} = (\Sigma, \mathcal{O}, \mathcal{T}_\varepsilon).$$

Для решения конкретной задачи $\mathcal{P} \in \mathcal{F}$ естественно применить некую *итеративную процедуру*. Именно в таком виде удобно записывать любой метод $\mathcal{M}$, работающий с оракулом $\mathcal{O}$.

Эффективность численных методов оптимизации

В настоящее время не существует универсальных методов решения задач оптимизации.

Невозможно определить наилучший метод решения некоторой задачи $\mathcal{P}$. Однако возможно определить класс методов для определенного класса задач. Т.е. класс задач $\mathcal{F}$, где $\mathcal{P} \subset \mathcal{F}$ и $\mathcal{F}$ - выделенный класс задач. Обычно численные методы разрабатываются для решения многих однотипных задач с близкими характеристиками. Поэтому эффективность метода $\mathcal{M}$ на всем классе задач $\mathcal{F}$ можно считать естественной характеристикой его качества.

При этом следует учитывать, что метод $\mathcal{M}$ не имеет полной информации о решаемой задаче.

Теорема о «бесплатных завтраках»

- Теорема Дэвида Волперта и Уильяма Макриди о бесплатном обеде (иногда во множественном числе) “No Free Lunch” (NFL) появляется в 1997 году в "No Free Lunch Theorems for Optimization». Название отсылает к поговорке «Бесплатных завтраков не бывает», то есть нет простых путей к успеху.

- **Формулировка теоремы**

Если алгоритм хорошо работает над определенным классом задач, то он обязательно платит за это снижением производительности на множестве всех оставшихся задач.

Эффективность численных методов оптимизации

Общая итеративная схема

Вводные данные: начальная точка x_0 и требуемая точность $\varepsilon > 0$.

Настройка. Полагаем $k = 0$ и $I_{-1} = \emptyset$. Здесь k — это счетчик итераций, а I_k — это накапливаемая информационная модель решаемой задачи.

Основной цикл.

Шаг 1. Задаем вопрос оракулу $\mathcal{O}$ в точке x_k .

Шаг 2. Пересчитываем информационную модель: $I_k = I_{k-1} \cup (x_k, \mathcal{O}(x_k))$.

Шаг 3. Применяем правила метода $\mathcal{M}$ для анализа модели I_k и формируем точку x_{k+1} .

Шаг 4. Проверяем критерий остановки $\mathcal{T}_\varepsilon$. Если ответ положительный, то генерируем ответ $\bar{x}$. В противном случае полагаем $k := k + 1$ и переходим на шаг 1.

Эффективность численных методов оптимизации

Наиболее трудоемкими являются два шага. Первый — это обращение к оракулу $\mathcal{O}$ Шаг 1. Второй Шаг 3, на котором анализируется накопленная модель и формируется следующая тестовая точка.

Таким образом, можно ввести две меры сложности задачи $\mathcal{P}$ и для метода $\mathcal{M}$.

Аналитическая сложность. Это число обращений к оракулу, необходимое для решения задачи $\mathcal{P}$ с точностью ε .

Арифметическая сложность. Это общее число всех вычислений (включая как работу оракула, так и работу метода), необходимых для решения задачи $\mathcal{P}$ с точностью ε .

Эффективность численных методов оптимизации

Общая итеративная схема

Вводные данные: начальная точка x_0 и требуемая точность $\varepsilon > 0$.

Настройка. Полагаем $k = 0$ и $I_{-1} = \emptyset$. Здесь k — это счетчик итераций, а I_k — это накапливаемая информационная модель решаемой задачи.

Основной цикл.

Шаг 1. Задаем вопрос оракулу $\mathcal{O}$ в точке x_k .

Шаг 2. Пересчитываем информационную модель: $I_k = I_{k-1} \cup (x_k, \mathcal{O}(x_k))$.

Шаг 3. Применяем правила метода $\mathcal{M}$ для анализа модели I_k и формируем точку x_{k+1} .

Шаг 4. Проверяем критерий остановки $\mathcal{T}_\varepsilon$. Если ответ положительный, то генерируем ответ $\bar{x}$. В противном случае полагаем $k := k + 1$ и переходим на шаг 1.

Эффективность численных методов оптимизации


Наиболее трудоемкими являются два шага. Первый — это обращение к оракулу $\mathcal{O}$ Шаг 1. Второй Шаг 3, на котором анализируется накопленная модель и формируется следующая тестовая точка.

Таким образом, можно ввести две меры сложности задачи $\mathcal{P}$ и для метода $\mathcal{M}$.

Аналитическая сложность. Это число обращений к оракулу, необходимое для решения задачи $\mathcal{P}$ с точностью ε .

Арифметическая сложность. Это общее число всех вычислений (включая как работу оракула, так и работу метода), необходимых для решения задачи $\mathcal{P}$ с точностью ε .

Наиболее трудоемкие как правило Шаг 1 и Шаг 3



4.3. ОРАКУЛЫ

О – 0-порядка

1. Метод Хука-Дживса
2. Метод Розенброка
3. Метод Нелдера-Мида

О – 1-порядка

Методы сопряженных градиентов:

1. Флэтчера – Ривза
2. Полака – Рибьера

О – 2-порядка

Методы переменной метрики:

1. Бройдена
2. Дэвидона-Флэтчера-Пауэлла
3. Бройдена-Флэтчера-Гольдфарба-Шанно

Оракул – 0. Методы 0-го порядка.

- **Метод Хука-Дживса**

- 1. *Выбор направления (исследующий поиск)***




- $x(0)$ и Δ – приращение по каждой координате.
- Рассчитываем значение целевой функции при приращении по каждой координате
$$x(1) = x(0) + \Delta.$$
- Если приращение улучшает значение целевой функции, то шаг считается удачным и дается приращение по другой координате, в противном случае – неудачным, тогда движение делается в $-\Delta$ направлении.
- Если и этот шаг неудачный, то $x(0)$ остается неудачным и делается приращение по следующей координате, пока все координаты не будут перебраны. Таким образом, получим точку $x(1)$.
- Все шаги стали «неудачными», $\Delta x := \Delta x / 2$

- 2. *Движение по образцу:*** $x(n+1) = x(n) + (x(n) - x(n-1)) = 2x(n) - x(n-1).$

И т.д. См Шаг1. Проверяем условие остановки.

Оракул – 0. Методы 0-го порядка.

Метод Нелдера-Мида (деформируемых многогранников).



https://ru.wikipedia.org/wiki/Метод_Нелдера_—_Мида

Оракул – 1. Методы 1-го порядка

Методы сопряженных градиентов

• Метод Флетчера-Ривза и Полака-Рибьера.

Ш.1. Задать $x^0, \varepsilon_1, \delta_2, \varepsilon_2, M$ - предельное число итераций. Вычислить градиент $\nabla f(x^0)$.

Ш.2. Положить $k = 0$.

Ш.3. Вычислить $\nabla f(x^k)$.

Ш.4. Проверить выполнение критерия окончания $\|\nabla f(x^k)\| < \varepsilon_1$:

a) если критерий выполнен, $x^* = x^k$, расчет заканчивается;

b) если нет, то перейти на Ш.5.

Ш.5. Проверить условие $k \geq M$:

a) если неравенство выполняется, то расчет окончен и $x^* = x^k$;

b) если нет, то при $k = 0$ перейти на Ш.6., а при $k \geq 1$ перейти на Ш.7.

Ш.6. Определить $d^0 = -\nabla f(x^0)$.

Ш.7. Определить

$$w^{k-1} = \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^{k-1})\|^2}, \text{ или } w^{k-1} = \begin{cases} \frac{\langle \nabla f(x^k), [\nabla f(x^k) - \nabla f(x^{k-1})] \rangle}{\|\nabla f(x^{k-1})\|^2}, & k \notin J, \\ 0, & k \in J. \end{cases}$$

Ш.8. Определить $d^k = -\nabla f(x^k) + w^{k-1}d^{k-1}$.

Ш.9. Найти α^{*k} из условия $\alpha^{*k} = \underset{\alpha^k \in \mathbb{R}^1}{\operatorname{Argmin}} f(x^k + \alpha^k d^k)$.

Ш.10. Вычислить $x^{k+1} = x^k + \alpha^k d^k$.

Ш.11. Проверить выполнение условий $\|x^{k+1} - x^k\| < \delta_2, |f(x^{k+1}) - f(x^k)| < \varepsilon_2$:

a) в случае выполнения обоих условий в двух последовательных итерациях с номерами k и $k-1$ расчет окончен, найдена точка $x^* = x^k$.

b) если не выполняется хотя бы одно из условий, полагаем $k = k+1$ и переход на Ш.3.

Оракул – 1. Методы 1-го порядка

Методы сопряженных градиентов

$\alpha^k \in \mathbb{R}^n$

Стратегия поиска.

Стратегия метода Флетчера-Ривза (FR) состоит в построении последовательности точек $\{x^k\}$, $k = 0, 1, \dots$, таких, что $f(x^{k+1}) < f(x^k)$, $k = 0, 1, \dots$. Точки последовательности $\{x^k\}$ вычисляются по правилу:

$$x^{k+1} = x^k + \alpha^k d^k, \quad k = 0, 1, \dots; \quad (4.1.1.)$$

$$d^k = -\nabla f(x^k) + w^{k-1} d^{k-1}; \quad (4.1.2.)$$

$$d^0 = -\nabla f(x^0); \quad (4.1.3.)$$

$$w^{k-1} = \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^{k-1})\|^2}. \quad (4.1.4.)$$

Точка x^0 задается пользователем, величина шага α^{*k} определяется для каждого значения k из условия $\alpha^{*k} = \underset{\alpha^k \in \mathbb{R}^1}{\operatorname{Arg\,min}} f(x^k + \alpha^k d^k)$. Решение задачи одномерной

минимизации может осуществляться либо из условия $\frac{d\varphi(\alpha^k)}{d\alpha^k} = 0, \frac{d^2\varphi(\alpha^k)}{d\alpha^{k2}} > 0$, либо

численно, с использованием методов одномерной минимизации, когда решается задача:

$$\varphi(\alpha^k) \rightarrow \min_{\alpha^k \in [a, b]}. \quad (4.1.5.)$$

При численном решении задачи определения величины шага степень близости найденного значения α^k к оптимальному значению α^{*k} , удовлетворяющему условиям $\frac{d\varphi(\alpha^k)}{d\alpha^k} = 0, \frac{d^2\varphi(\alpha^k)}{d\alpha^{k2}} > 0$, зависит от задания интервала $[a, b]$ и точности одномерной минимизации.

Вычисление величины w^{k-1} по формуле (4.1.4.) обеспечивает для квадратичной формы $f(x) = \sum_{i=1}^n \sum_{j=1}^n x_i x_j$ построение последовательности H -сопряженных направлений $d^0, d^1, \dots, d^k, \dots$, для которых $\langle d^i, H d^j \rangle = 0, \forall i, j = 0, 1, \dots, k; i \neq j$. При этом в точках последовательности $\{x^k\}$ градиенты функции $f(x)$ взаимно перпендикулярны, т.е. $\langle \nabla f(x^{k+1}), \nabla f(x^k) \rangle = 0, k = 0, 1, \dots$.

Для квадратичных функций $f(x)$ с матрицей $H > 0$ метод Флетчера-Ривза является конечным и сходится за число шагов, не превышающее n - размерность x вектора переменных.

При минимизации неквадратичных функций метод не является конечным, при этом следует отметить, что погрешность в решении задачи (4.1.5.) приводит к нарушению не только перпендикулярности градиентов, но и H -сопряженности направлений. Для неквадратичных функций, как правило, используется алгоритм Полака-Рибьера, когда в формулах (4.1.1. – 4.1.3.) величина w^{k-1} вычисляется следующим образом:

$$w^{k-1} = \begin{cases} \frac{\|\nabla f(x^k)\|^2}{\|\nabla f(x^{k-1})\|^2}, & k \notin J, \\ 0, & k \in J, \end{cases} \quad w^{k-1} = \begin{cases} \frac{\langle \nabla f(x^k), [\nabla f(x^k) - \nabla f(x^{k-1})] \rangle}{\|\nabla f(x^{k-1})\|^2}, & k \notin J, \\ 0, & k \in J, \end{cases}$$

где $J = \{0, n, 2n, \dots\}$. В отличие от алгоритма Флетчера-Ривза алгоритм Полака-Рибьера предусматривает использование итерации наискорейшего спуска через каждые n шагов. Построение последовательности $\{x^k\}$ заканчивается в точке, для которой $\|\nabla f(x^k)\| < \varepsilon_1$, где $\varepsilon_1 > 0$ - заданное число, или при $k \geq M$, M - предельное число итераций, или при двукратном одномерном выполнении двух неравенств $\|x^{k+1} - x^k\| < \delta_2, |f(x^{k+1}) - f(x^k)| < \varepsilon_2$, где δ_2, ε_2 - малые положительные числа. Вопрос о том, может ли точка x^k рассматриваться как найденное приближение искомой точки минимума, решается путем проведения дополнительного исследования.

Оракул – 2. Методы 2-го порядка

Квазиньютоновские методы (DFP)

4.2.3. Метод Девидона-Флетчера-Пауэлла.

Постановка задачи

Пусть дана функция $f(x)$, ограниченная снизу на множестве R^n и имеющая непрерывные частные производные во всех его точках (т.е. $f(x) \in C^1(X)$, $X = R^n$).

Требуется найти локальный минимум функции $f(x)$ на множестве допустимых решений $X = R^n$, т.е. найти такую точку $x^* \in R^n$, что $f(x^*) = \min_{x \in R^n} f(x)$.

Стратегия поиска.

Стратегия метода Девидона-Флетчера-Пауэлла (DFP) состоит в построении последовательности точек $\{x^k\}$, таких, что $f(x^{k+1}) < f(x^k)$, $k = 0, 1, \dots$. Точки последовательности $\{x^k\}$ вычисляются по правилу:

$$x^{k+1} = x^k - \alpha^{*k} G^{k+1} \nabla f(x^k), \quad k = 0, 1, \dots, \quad (4.2.1.)$$

где G^{k+1} - матрица размера $n \times n$, являющаяся аппроксимацией обратной матрицы Гессе. Она вычисляется по правилу:

$$G^{k+1} = G^k + \Delta G^k, \quad G^0 = E, \quad (4.2.2.)$$

$$\Delta G^k = \frac{\Delta x^k (y^k)^T}{(y^k)^T \Delta g^k} - \frac{G^k \Delta g^k (G^k \Delta g^k)^T}{(\Delta g^k)^T G^k \Delta g^k}, \quad (4.2.3.)$$

где $\Delta x^k = x^{k+1} - x^k$, $\Delta g^k = \nabla f(x^{k+1}) - \nabla f(x^k)$.

Точка x^0 задается пользователем, величина шага α^{*k} определяется из условия:

$$\alpha^{*k} = \text{Arg} \min_{\alpha^k \in [a, b]} \varphi(x^k + \alpha^k d^k). \quad (4.2.4.)$$

Решение задачи (4.2.4.) может выполняться как из условия $\frac{d\varphi(\alpha)}{d\alpha^k} = 0$, $\frac{d^2\varphi(\alpha)}{d\alpha^{k2}} > 0$, либо численно, с использованием методов одномерной минимизации, когда решается задача: $\varphi(\alpha^k) \rightarrow \min_{\alpha^k \in [a, b]}$ оптимизации.

Формулы (4.2.2.), (4.2.3.) при аналитическом решении задачи (4.2.4.) обеспечивают построение последовательности $\{G^k\}$ положительно определенных матриц, таких, что $G^k \rightarrow H^{-1}(x^*)$ при $k \rightarrow \infty$. Следствием этого для квадратичной функции

$f(x) = \frac{1}{2} \langle Hx, x \rangle + \langle b, x \rangle$, $H > 0$, является тот факт, что направления d^k , $k = 0, 1, \dots$, будут

H -сопряженными и, следовательно, алгоритм DFP сойдется не более чем за n шагов.

Для неквадратичных функций $f(x)$ алгоритм DFP перестаёт быть конечным и его сходимость зависит от точности решения задачи (4.2.4.). Глобальную сходимость алгоритма можно гарантировать лишь при его обновлении через каждые n шагов, т.е. когда в формуле (4.2.1.):

$$G^{k+1} = \begin{cases} E, & k \in J; J = \{0, n, 2n, \dots\}, \\ G^k + \Delta G^k, & k \notin J. \end{cases}$$

Построение последовательности $\{x^k\}$ заканчивается в точке x^{*k} , для которой $\nabla f(x^k) < \varepsilon_1$, где ε_1 - заданное число, или при $k \geq M$ (M - предельное число итераций),

или при двукратном одновременном выполнении двух неравенств: $\|x^{k+1} - x^k\| < \delta_2$, $|f(x^{k+1}) - f(x^k)| < \varepsilon_2$, где $\delta_2 > 0, \varepsilon_2 > 0$ - малые положительные числа.

Вопрос о том, может ли точка x^k рассматриваться как найденное приближение искомой точки x^* минимума, решается путем проведения дополнительного исследования.

Оракул – 2. Методы 2-го порядка

Квазиньютоновские методы (BFGS)

Метод BFGS (Бройдена, Флэтчера, Гольдфарба, Шанно).

B – Broyden, F – Fletcher, G – Goldfarb, S – Shanno

Считается самым оптимальным и эффективным методом:

SciPy: `scipy.optimize.BFGS`



Оракул – 2. Методы 2-го порядка

Квазиньютоновские методы

• Алгоритм BFGS

Пусть задана целевая функция $f(x): x \rightarrow R, x \in R^n$, решаем задачу многомерной оптимизации.

1. Выбираем $x^{(0)}$ – начальную точку приближения, задаем точность $\varepsilon > 0$, вычисляем $H^{-1}(x^{(0)}) = [\nabla^2 f(x)]^{-1}$ либо $\eta^{(0)} = E$ (единичная матрица, которая хорошо обусловлена и невырождена)
2. Вектор направления поиска: $p^{(k)} = -H^{-1}(x^{(k)}) \cdot \nabla f(x^{(k)})$, где $H^{-1}(x^{(k)}) = E$
3. Релаксационная последовательность:

$$x^{(k+1)} = x^{(k)} + \alpha^{(k)} p^{(k)}, \quad \alpha^{(k)} \in R, p^{(k)} \in R^n, x^{(k)} \in R^n$$

$$g^{(k)}(\alpha^{(k)}) = \min_{\alpha > 0} f(x^{(k)} + \alpha p^{(k)}), \text{ важно}$$

$\alpha^{(k)}$ должно удовлетворять условию Вольфе:

$$f(x^{(k)} + \alpha^{(k)} p^{(k)}) \leq f(x^{(k)}) + c_1 \cdot \alpha^{(k)} (\nabla f(x^{(k)}), p^{(k)})$$

и $(\nabla f(x^{(k)} + \alpha^{(k)} p^{(k)}), p^{(k)}) \geq c_2 \cdot (\nabla f(x^{(k)}), p^{(k)})$, где

$$0 \leq c_1 \leq c_2 \leq 1, \text{ как правило } c_1 = 0.0001, c_2 = 0.9$$

4. Вычисляем $\Delta x^{(k)} = x^{(k+1)} - x^{(k)}$, $\Delta g^{(k)} = \nabla f(x^{(k+1)}) - \nabla f(x^{(k)})$, где $\Delta x^{(k)}$ – шаг алгоритма на k -й итерации,

$\Delta g^{(k)}$ – изменение градиента на k -й итерации.

5. Пересчитываем $\eta^{(k+1)}$:

$$\eta^{(k+1)} = \left(E - \rho^{(k)} \cdot (\Delta x^{(k)} \otimes \Delta g^{(k)}) \right) \cdot \eta^{(k)} \cdot \left(E - \rho^{(k)} \cdot (\Delta g^{(k)} \otimes \Delta x^{(k)}) \right) + \\ + \rho^{(k)} \cdot (\Delta x^{(k)} \otimes \Delta x^{(k)}), \text{ где } \rho^{(k)} = \frac{1}{(\Delta g^{(k)}, \Delta x^{(k)})}.$$

Бройден-Флетчер-Гольдфарб-Шенно



ЛИТЕРАТУРА

1. Васильев Ф.П. "Методы оптимизации"

Издательство: Факториал Пресс, 2002 (переиздания)

Классический фундаментальный учебник

Охватывает линейное и нелинейное программирование, численные методы

2. Пантелеев А.В., Летова Т.А. "Методы оптимизации в примерах и задачах"

Издательство: Высшая школа, 2005 (переиздания 2015)

Практико-ориентированный подход

Содержит большое количество решенных задач

3. Карманов В.Г. "Математическое программирование"

Издательство: Физматлит, 2004 (переиздания)

Теория и численные методы

Подходит для углубленного изучения

4. Аттетков А.В., Галкин С.В., Зарубин В.С. "Методы оптимизации"

Издательство: МГТУ им. Баумана, 2003 (переиздания 2014)

Учебник для технических вузов

Акцент на инженерных приложениях

5. Измаилов А.Ф., Солодов М.В. "Численные методы оптимизации"

Издательство: Физматлит, 2005, 2008

Современные алгоритмы оптимизации

Строгое математическое изложение

1. Boyd S., Vandenberghe L. "Convex Optimization"

Cambridge University Press, 2004 Классика! Наиболее цитируемая книга по выпуклой оптимизации Доступна бесплатно на сайте авторов Теория + практические алгоритмы

2. Nocedal J., Wright S.J. "Numerical Optimization"

Springer, 2006 (2nd edition) Фундаментальный учебник по численным методам. Охватывает линейное, нелинейное программирование, методы внутренней точки. Стандарт для курсов по оптимизации

3. Bertsekas D.P. "Convex Optimization Theory"

Athena Scientific, 2009 Строгое математическое изложение. Глубокое понимание теории выпуклости. Дополняет книгу Boyd & Vandenberghe

4. Beck A. "First-Order Methods in Optimization"

SIAM, 2017 Современные методы первого порядка. Акцент на методах для больших данных и ML Gradient descent, proximal methods, ADMM

5. Nesterov Y. "Lectures on Convex Optimization"

Springer, 2018 (2nd edition) От создателя accelerated gradient method. Современные алгоритмы с оптимальной сложностью Продвинутый уровень Дополнительно (специализированные темы):

6. Bubeck S. "Convex Optimization: Algorithms and Complexity"

Foundations and Trends in Machine Learning, 2015. Краткий обзор (100 страниц). Доступен бесплатно онлайн. Связь оптимизации и машинного обучения

7. Wright S.J., Recht B. "Optimization for Data Analysis"

Cambridge University Press, 2022 Самая современная! Оптимизация для анализа данных и ML Stochastic methods, distributed optimization

Онлайн-ресурсы: Курсы Stanford (Boyd), MIT (Bertsekas) — доступны бесплатно

Arxiv.org — последние исследования в области оптимизации

Спасибо за внимание!

Каганов Юрий Тихонович

yurijkaganov@gmail.com

kaganov y.t@bmstu.ru