

Лекция № 4

Ю.Т. Каганов, к.т.н., доцент, кафедра ИУ-5

Методы условной оптимизации

Методы условной оптимизации

(методы математического программирования с учетом ограничений)

Методы нелинейного программирования.

1. **Прямые методы** – это методы, где последовательно решаются задачи оптимизации таким образом, что на каждом этапе процесс решения не выходит за пределы активных ограничений.
 - 1.1. Методы проекции градиента.
 - 1.2. Методы решения уравнений Куна-Таккера.
2. **Двойственные методы** – ряд методов, которые строят вспомогательную функцию по аналогии с двойственной функцией Лагранжа.
 - 2.1. Методы штрафных функций
 - 2.1.2. Методы внешних штрафов.
 - 2.1.3. Методы внутренних штрафов (метод барьерных функций).
 - 2.1.4. Метод последовательной безусловной оптимизации (МПБМ-SUMT).
 - 2.2. Лагранжевы методы.
 - 2.2.1. Метод Удзавы и Эрроу-Гурвица.
 - 2.2.2. Методы модифицированных функций Лагранжа.

Задача оптимизации с ограничениями

Постановка задачи

1. Общая задача оптимизации:

- $\min f(w)$
- при ограничениях: $g_i(w) \leq 0, i = 1, \dots, m$ (неравенства)
 $h_j(w) = 0, j = 1, \dots, p$ (равенства)

Примеры в ML:

1. SVM:

$$\min \frac{1}{2} \|w\|^2$$

w, b

$$\text{при: } y_i(w^T x_i + b) \geq 1, \forall i$$

2. Оптимизация с регуляризацией:

$$\min L(w)$$

$$W \text{ при: } \|w\|_1 \leq C \text{ (LASSO)}$$

3. Ограниченная оптимизация: $\min f(w)$ при: $w_i \geq 0, \sum w_i = 1$ (например, веса портфеля)

Функция Лагранжа

Определение:

- $\mathcal{L}(w, \alpha, \beta) = f(w) + \sum_i \alpha_i g_i(w) + \sum_j \beta_j h_j(w)$

где:

- $\alpha = (\alpha_1, \dots, \alpha_m)$ - множители Лагранжа для неравенств
- $\beta = (\beta_1, \dots, \beta_p)$ - множители Лагранжа для равенств
- $\alpha_i \geq 0$ для всех i

Свойство:

- $\max_{\alpha \geq 0, \beta} \mathcal{L}(w, \alpha, \beta) = \begin{cases} f(w), & \text{если } w \text{ допустимо} \\ +\infty, & \text{иначе} \end{cases}$

ЗАДАЧА НЕЛИНЕЙНОГО ПРОГРАММИРОВАНИЯ

$$\begin{array}{ll} f(x) \rightarrow \min; & f(x) \rightarrow \min; \\ h_j(x) = 0, \quad j = 1, 2, \dots, l; & h(x) = 0, \\ g_k(x) \leq 0, \quad k = l + 1, \dots, m. & g(x) \leq 0. \end{array} \quad \text{Или}$$

$$L(x, \lambda, \mu) = \lambda_0 f(x) + \sum_{j=1}^l \lambda_j h_j(x) + \sum_{k=l+1}^m \mu_k g_k(x)$$

Элементы X , удовлетворяющие ограничениям задачи называются **допустимыми решениями**.

Терема Куна-Таккера (Каруша-Джона)

Если точка x^* есть решение задачи математического программирования, то найдутся такие числа $\lambda_0^*, \lambda_1^*, \lambda_2^*, \dots, \lambda_l^*$, и $\mu_{l+1}^*, \dots, \mu_m^*$ не все равные нулю, что

$$\lambda_0^* \nabla f(x^*) + \sum_{j=1}^l \lambda_j^* \nabla h_j(x^*) + \sum_{k=l+1}^m \mu_k^* \nabla g_k(x^*) = 0,$$

причем $\lambda_0^* \geq 0$ а все $\mu_k^* \geq 0$,

при этом $\mu_k^* g_k(x^*) = 0, \quad k = l + 1, \dots, m$ - называется условием **дополняющей нежесткости**.

Теорема Каруша-Куна-Таккера

- **Теорема Куна-Таккера** (Kuhn-Tucker) — это фундаментальный результат в теории математической оптимизации, обобщающий метод множителей Лагранжа на задачи с ограничениями в форме неравенств. Она играет ключевую роль в машинном обучении, особенно в задачах обучения с ограничениями, SVM (Support Vector Machines) и других оптимизационных моделях.

Условия Каруша-Куна-Таккера (ККТ)

Теорема КТТ (достаточные условия для выпуклой задачи):

- Если f , g_i выпуклы, h_j аффинны, и выполнены условия регулярности, то w^* оптимально $\Leftrightarrow$

1. Стационарность:

- $\nabla_m \mathcal{L}(w, \alpha, \beta^*) = 0 \Leftrightarrow \nabla f(w) + \sum \alpha_i \nabla g_i(w) + \sum \beta_j \nabla h_j(w^*) = 0$

2. Допустимость прямой задачи:

- $g_i(w^*) \leq 0, \forall i$
- $h_j(w^*) = 0, \forall j$

3. Допустимость двойственной задачи:

- $\alpha_i^* \geq 0, \forall i$

4. Комплементарность (complementary slackness – условие дополняющей нежесткости):

- $\alpha_i g_i(w) = 0, \forall i$

Интерпретация комплементарности:

- Если ограничение не активно ($g_i(w) < 0$), то $\alpha_i = 0$
- Если $\alpha_i > 0$, то ограничение активно ($g_i(w) = 0$)

Двойственность в задачах оптимизации и в машинном обучении.

- Двойственность — это важный концепт как в теории оптимизации, так и в машинном обучении. Она позволяет получить дополнительную информацию о проблемах оптимизации и может значительно упростить вычисления.

Двойственность

Исходная задача (primal):

- $p^* = \min \max \mathcal{L}(w, \alpha, \beta)$
- $w \quad \alpha \geq 0, \beta$

Двойственная задача (dual):

- $d^* = \max \min \mathcal{L}(w, \alpha, \beta)$
- $\alpha \geq 0, \beta \quad w$

Теорема слабой двойственности:

- $d \leq p$

Двойственность в задачах оптимизации

- В контексте линейного программирования, каждая задача (прямая) имеет соответствующую двойственную задачу. Если у нас есть задача минимизации:
- $\min c^T x$
- при условии $Ax \leq b, x \geq 0$,
- то соответствующая двойственная задача будет выглядеть следующим образом:
- $\max b^T y$
- при условии $A^T y = c, y \geq 0$.
- Здесь:
- c — вектор коэффициентов целевой функции,
- A — матрица ограничений,
- b — вектор правых частей ограничений,
- x — вектор переменных прямой задачи,
- y — вектор двойственных переменных (множителей Лагранжа $y = \lambda$)

РЕГУЛЯРИЗАЦИЯ

Борьба с переобучением

Проблема переобучения:

$$\min L(w) = (1/n) \sum \text{Loss}(y_i, f(x_i; w))$$

- Модель "запоминает" обучающие данные
- Плохая генерализация на новых данных

Решение - регуляризация:

- $\min L(w) + \lambda R(w)$
- где $R(w)$ - регуляризатор, $\lambda > 0$ - сила регуляризации

Интерпретации:

1. Байесовская:

- $R(w)$ соответствует prior $p(w)$
- MAP оценка: $w^* = \operatorname{argmax} p(w|X, y) = \operatorname{argmax} p(y|X, w)p(w)$

2. Ограничение:

$\min L(w)$ при $R(w) \leq C$ эквивалентно (по ККТ) задаче с λ

3. Regularization by penalty:

"Штраф" за сложность модели

L2 регуляризация

Гребневая регрессия (Ridge Regression)

Определение:

- $R(w) = \frac{1}{2} \|w\|_2^2 = \frac{1}{2} \sum w_i^2$

Задача оптимизации:

- $\min (1/2n) \|Xw - y\|^2 + (\lambda/2) \|w\|^2$

Аналитическое решение:

- $w^* = (X^T X + \lambda I)^{-1} X^T y$

Градиент:

- $\nabla(L + \lambda R) = \nabla L + \lambda w$

Обновление в SGD:

- $w_{t+1} = w_t - \eta(\nabla L(w_t) + \lambda w_t) = (1 - \eta\lambda)w_t - \eta\nabla L(w_t)$

Свойства:

- ✓ Гладкая, дифференцируемая
- ✓ Аналитическое решение (для линейных моделей)
- ✓ Штрафует большие веса $\rightarrow$ предотвращает переобучение
- ✓ Улучшает обусловленность ($X^T X + \lambda I$ лучше обусловлена)
- ⚠ Не обнуляет веса (feature selection невозможен)

L1 регуляризация – LASSO

Least Absolute Shrinkage and Selection Operator

Определение:

$$R(w) = \|w\|_1 = \sum |w_i|$$

Задача оптимизации:

- $\min (1/2n) \|Xw - y\|^2 + \lambda \|w\|$

Субградиент:

- $\partial \|w\|_1 = \text{sign}(w)$ для $w \neq 0 \in [-1, 1]$ для $w = 0$

Проксимальный оператор (soft thresholding):

- $w_{i,t+1} = \text{sign}(w_{i,t}) \max(|w_{i,t}| - \eta\lambda, 0)$

Ключевое свойство: Sparsity (разреженность)

- L1 обнуляет некоторые веса!
- Автоматический выбор признаков
- Интерпретируемые модели

Сравнение L1 vs L2

Свойство	L2 (Ridge)	L1 (LASSO)
-----	-----	-----
Форма	Круг	Ромб
Решение	Аналитическое	Численное
Веса	Малые	Разреженные (нули)
Feature selection	Нет	Да
Устойчивость	Да	Меньше

Двойственность в машинном обучении

- В машинном обучении концепция двойственности часто используется в контексте задач, связанных с методом опорных векторов (SVM). В SVM мы стремимся максимизировать зазор между классами, что может быть сформулировано как задача оптимизации:
- $\min \frac{1}{2} \|w\|^2$
- При условии $y_i(w^T x_i + b) \geq 1, \forall i,$
- где w — вектор весов, b — смещение, x_i — входные данные, а y_i — метки классов.
- Соответствующая двойственная задача будет:
- $\max \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^m \alpha_i \alpha_j y_i y_j (x_i^T x_j)$
- при условии: $\sum_{i=1}^n \alpha_i y_i = 0, \alpha_i \geq 0.$

Метод опорных векторов (SVM)

- **1. Основные формулы и алгоритм**
- **Линейный SVM для бинарной классификации**
- **Цель:** Найти гиперплоскость, максимально разделяющую классы.
- **Уравнение разделяющей гиперплоскости:**
- $w^T x + b = 0$
- где w - вектор нормали, b - смещение
- **Классификация точки:**
- $y = \text{sign}(w^T x + b)$
- **Задача оптимизации**
- **Прямая задача (Hard Margin):**
- $\min\{w, b\} \left(\frac{1}{2}\right) ||w||^2$
-
- при условиях: $y_i(w^T x_i + b) \geq 1$, для всех i

Метод опорных векторов (SVM)

- **Soft Margin SVM** (с допустимыми ошибками):
- $\min\{w, b\} \left(\frac{1}{2} \right) \|w\|^2 + C \sum \xi_i$
-
- при условиях:
- $-y_i(w^T x_i + b) \geq 1 - \xi_i$
- $\xi_i \geq 0$
- где:
- **C** - параметр регуляризации (баланс между максимизацией зазора и минимизацией ошибок)
- ξ_i - переменные слабины (slack variables)

Метод опорных векторов (SVM)

- 2. "Ядерный трюк" (Kernel Trick)
- Концепция
- Вместо явного отображения данных в высокоразмерное пространство $\varphi(x)$, используем **функцию ядра**:
- $K(x_i, x_j) = \varphi(x_i)^T \varphi(x_j)$
- Двойственная задача с ядром
- $\max_{\alpha} \sum \alpha_i - \left(\frac{1}{2}\right) \sum \sum \alpha_i \alpha_j y_i y_j K(x_i, x_j)$
- Классификация:
- $f(x) = \text{sign}(\sum \alpha_i y_i K(x_i, x) + b)$

Метод опорных векторов (SVM)

- Популярные функции ядра
- Линейное ядро:
 - $K(x, x') = x^T x'$
- Полиномиальное ядро:
 - $K(x, x') = (\gamma x^T x' + r)^d$
- **RBF** (Радиальная базисная функция, Гауссово ядро):
 - $K(x, x') = \exp(-\gamma \|x - x'\|^2)$
- Сигмоидное ядро:
 - $K(x, x') = \tanh(\gamma x^T x' + r)$

Метод опорных векторов (SVM)

- **Преимущества ядерного трюка**
 - . Не нужно явно вычислять $\phi(x)$
 - . Работа в бесконечномерных пространствах
 - . Вычислительная эффективность

Метод опорных векторов (SVM)

3. Алгоритм обучения *SVM*

- Шаги:

1. Выбор ядра и параметров (C, γ и др.)
2. Формирование задачи оптимизации с матрицей ядер
3. Решение задачи квадратичного программирования:
 1. *Sequential Minimal Optimization (SMO)*
 2. *Gradient descent methods*
 3. *Coordinate descent*
4. Определение опорных векторов ($\alpha_i > 0$)
5. Вычисление смещения b :

$$b = y_s - \sum \alpha_i y_i K(x_i, x_s)$$

для опорного вектора x_s

Метод опорных векторов (SVM)

- **Двойственная задача (Dual Problem)**
- $\max_{\alpha} \sum \alpha_i - \left(\frac{1}{2}\right) \sum \sum \alpha_i \alpha_j y_i y_j (x_i^T x_j)$
-
- при условиях:
- $- 0 \leq \alpha_i \leq C$
- $-\sum \alpha_i y_i = 0$
- **Решение:**
- $w = \sum \alpha_i y_i x_i$
- **Опорные векторы** - объекты с $\alpha_i > 0$

SVM vs Нейронные сети

Аспект	SVM	Нейронные сети
-----	-----	-----
Оптимизация	Выпуклая (QP)	Невыпуклая
Решение	Глобальный оптимум	Локальный минимум
Гиперпараметры	C, kernel params	Много (архитектура, η , ...)
Интерпретируемость	Опорные векторы	Черный ящик
Масштабируемость	Плохая ($O(n^2)$)	Хорошая (SGD)
Feature engineering	Важен выбор ядра	Автоматический
Малые данные	✓ Хорошо	⚠ Переобучение
Большие данные	✗ Проблемы	✓ Отлично
Высокая размерность	✓ Kernel trick	✓ Deep learning

Когда использовать SVM:

- ✓ Малые/средние датасеты (< 10K примеров)
- ✓ Нужны теоретические гарантии
- ✓ Важна интерпретируемость
- ✓ Табличные данные с хорошими признаками

Когда использовать нейросети:

- ✓ Большие данные (> 100K примеров)
- ✓ Сложные структурированные данные (изображения, текст, аудио)
- ✓ Нужна автоматическая feature extraction
- ✓ Есть вычислительные ресурсы (GPU)

Двойственность в машинном обучении

Двойственность в задачах оптимизации и машинном обучении предоставляет мощные инструменты для анализа и решения задач. Она позволяет не только находить оптимальные решения, но и понимать взаимосвязи между различными задачами.

МЕТОДЫ ОПТИМИЗАЦИИ В МАШИННОМ ОБУЧЕНИИ

1. Goodfellow I., Bengio Y., Courville A. "Deep Learning"

MIT Press, 2016. **Библия глубокого обучения.** Глава 8: Optimization for Training Deep Models. Охватывает SGD, Adam, momentum, batch normalization. Доступна бесплатно: www.deeplearningbook.org.

2. Bottou L., Curtis F.E., Nocedal J. "Optimization Methods for Large-Scale Machine Learning"

SIAM Review, 2018, Vol. 60, No. 2. **Обзорная статья (100+ страниц).** Stochastic gradient methods, mini-batch methods. От классики до современных подходов Обязательно к прочтению!

3. Ruder S. "An Overview of Gradient Descent Optimization Algorithms"

arXiv:1609.04747, 2016. Популярный обзор алгоритмов градиентного спуска. SGD, Momentum, Nesterov, Adagrad, RMSprop, Adam. Практичный и понятный Доступен бесплатно на arxiv.org.

4. Sutskever I. "Training Recurrent Neural Networks"

PhD Thesis, University of Toronto, 2013. Оптимизация для RNN Hessian-free optimization. Влиятельная работа от сооснователя OpenAI.

5. Zhang A., Lipton Z.C., Li M., Smola A.J. "Dive into Deep Learning"

Cambridge University Press, 2023. **Современный интерактивный учебник.** Практическая оптимизация для DL. Код на PyTorch/TensorFlow. Бесплатно: d2l.ai.

6. Kingma D.P., Ba J. "Adam: A Method for Stochastic Optimization"

ICLR, 2015 (arXiv:1412.6980). Оригинальная статья про Adam optimizer. Один из самых используемых алгоритмов. Обязательно для понимания современной практики.

ЛИТЕРАТУРА

1. Васильев Ф.П. "Методы оптимизации"

Издательство: Факториал Пресс, 2002 (переиздания)

Классический фундаментальный учебник

Охватывает линейное и нелинейное программирование, численные методы

2. Пантелеев А.В., Летова Т.А. "Методы оптимизации в примерах и задачах"

Издательство: Высшая школа, 2005 (переиздания 2015)

Практико-ориентированный подход

Содержит большое количество решенных задач

3. Карманов В.Г. "Математическое программирование"

Издательство: Физматлит, 2004 (переиздания)

Теория и численные методы

Подходит для углубленного изучения

4. Аттетков А.В., Галкин С.В., Зарубин В.С. "Методы оптимизации"

Издательство: МГТУ им. Баумана, 2003 (переиздания 2014)

Учебник для технических вузов

Акцент на инженерных приложениях

5. Измаилов А.Ф., Солодов М.В. "Численные методы оптимизации"

Издательство: Физматлит, 2005, 2008

Современные алгоритмы оптимизации

Строгое математическое изложение

1. Boyd S., Vandenberghe L. "Convex Optimization"

Cambridge University Press, 2004 Классика! Наиболее цитируемая книга по выпуклой оптимизации Доступна бесплатно на сайте авторов Теория + практические алгоритмы

2. Nocedal J., Wright S.J. "Numerical Optimization"

Springer, 2006 (2nd edition) Фундаментальный учебник по численным методам. Охватывает линейное, нелинейное программирование, методы внутренней точки. Стандарт для курсов по оптимизации

3. Bertsekas D.P. "Convex Optimization Theory"

Athena Scientific, 2009 Строгое математическое изложение. Глубокое понимание теории выпуклости. Дополняет книгу Boyd & Vandenberghe

4. Beck A. "First-Order Methods in Optimization"

SIAM, 2017 Современные методы первого порядка. Акцент на методах для больших данных и ML Gradient descent, proximal methods, ADMM

5. Nesterov Y. "Lectures on Convex Optimization"

Springer, 2018 (2nd edition) От создателя accelerated gradient method. Современные алгоритмы с оптимальной сложностью Продвинутый уровень

Дополнительно (специализированные темы):

6. Bubeck S. "Convex Optimization: Algorithms and Complexity"

Foundations and Trends in Machine Learning, 2015. Краткий обзор (100 страниц). Доступен бесплатно онлайн. Связь оптимизации и машинного обучения

7. Wright S.J., Recht B. "Optimization for Data Analysis"

Cambridge University Press, 2022 Самая современная! Оптимизация для анализа данных и ML Stochastic methods, distributed optimization

Онлайн-ресурсы: Курсы Stanford (Boyd), MIT (Bertsekas) — доступны бесплатно

Arxiv.org — последние исследования в области оптимизации

Спасибо за внимание!

Каганов Юрий Тихонович

yurijkaganov@gmail.com

kaganov_y.t@bmstu.ru