




Обработка графов знаний с использованием методов машинного обучения



Графы знаний

- Графы знаний как средство улучшения искусственного интеллекта
- Граф знаний – это база знаний, использующая графовую (мульти, гипер-графовую) модель. Основная задача – обеспечение полноты знаний.
 - Тезаурус – специализированная база знаний, предназначенная для хранения (служебной) лингвистической информации.
 - Онтология – прежде всего схема данных, ориентированная на логический вывод. Основная задача – обеспечение непротиворечивости знаний.
- Наиболее известные проекты:
 - DBpedia
 - Yago
 - ConceptNet
 - Статья
 - Atomic 2020 (ориентирован на ситуации и причинно-следственные связи)
- Задачи, решаемые на графах знаний:
 - Предсказание вершин и связей.
 - Логический вывод на графе знаний (эта задача также решается на онтологиях)
 - Основой решения задач машинного обучения является embedding (векторное представление) графов знаний.
 - Статья «A Survey on Knowledge Graphs: Representation, Acquisition and Applications»
<https://arxiv.org/abs/2002.00388>
 - Статья «Knowledge Graph Embedding: A Survey of Approaches and Applications»
https://www.researchgate.net/publication/319947524_Knowledge_Graph_Embedding_A_Survey_of_Approaches_and_Applications

Направления исследований



Векторное представление графа знаний – 1

- Векторное представление (эмбеddинг) графа знаний – это математическое преобразование графа в вектор или в набор векторов в заданном векторном пространстве. Его можно проводить отдельно для вершин графа, для вершин и ребер графа, и даже для всего графа целиком. В первых двух случаях результатом будет набор векторов, в последнем – один вектор для целого графа. Главное условие состоит в том, что такое преобразование должно адекватно передавать семантику и топологию исходного графа. Эмбеddинг позволяет получить сразу несколько преимуществ при работе с графом знаний:
 1. Первое преимущество заключается в оптимизации использования памяти, ведь вектор – это сжатое представление информации из графа. Для действительно больших графов использование матрицы смежности напрямую становится сложно выполнимым, ведь для миллиона вершин размерность матрицы смежности составляет миллион в квадрате ячеек. Эмбеddинг в данном случае является более применимым решением, так как представляет узлы графа с помощью векторов гораздо меньшей размерности.
 2. Второе преимущество состоит в том, что мы получаем возможность использовать уже накопленный математический аппарат для методов машинного обучения, который позволяет работать с векторами.
 3. Третье преимущество состоит в производительности результирующих алгоритмов, использующих физическое представление графа знаний. В этом случае выполнение операций над векторами более производительнее, чем выполнение операций над традиционной графовой моделью в виде множеств вершин и ребер. Кроме того, на сегодняшний день видеокарты позволяют еще больше ускорить работу с векторами.

Векторное представление графа знаний – 2


- Процесс эмбединга графа знаний можно условно разделить на три этапа:
 1. Выбор того, каким образом будут представлены в векторном пространстве сущности и отношения. На данном этапе происходит задание способа представления сущностей и отношений в непрерывном векторном пространстве. Сущности обычно представляются в виде векторов (точек в векторном пространстве), а отношения задаются в виде операторов в этом векторном пространстве. В зависимости от используемых методов, отношения могут быть заданы в виде векторов (например, вектор суммы или разности), матриц, тензоров, Гауссовских распределений и их смесей.
 2. Задание функции правдоподобия преобразования (англ. scoring function). Для каждого RDF-триплета $\langle h, r, t \rangle$ задается функция правдоподобия $f(h, t)$. Чем больше значение этой функции, тем более вероятно то, что факт, описываемый триплетом, является истинным. Таким образом, в соответствии с функцией правдоподобия, факты, содержащиеся в графе знаний, набирают больше баллов, чем факты, которых нет в графе знаний.
 3. Обучение модели эмбединга подразумевает решение оптимизационной задачи, заключающейся в максимизации суммарной функции правдоподобия для всех триплетов, содержащихся в графе знаний.

Векторное представление графа знаний – 3

- На сегодняшний день существуют десятки различных техник эмбединга. Они различаются способами представления сущностей и отношений в векторном пространстве и способами задания функций правдоподобия. Основные модели эмбединга можно разделить на две группы: модели параллельного переноса и модели семантического соответствия:
 1. Модели параллельного переноса (англ. «translational distance models», TDM) используют функции правдоподобия, основанные на измерении расстояния между двумя вершинами графа. Причем оператор перемещения из одной вершины в другую задается на основе отношения между этими узлами в исходном графе.
 2. Модели семантического соответствия (англ. «semantic matching models», SMM) используют функции правдоподобия, основанные на семантических характеристиках вершин и отношений исходного графа.


Модель TransE (TDM)

- Эта модель представляет и узлы, и связи как векторы в одном и том же векторном пространстве. Причем оператор отношения рассматривается как вектор перемещения между субъектом и объектом. Это позволяет на интуитивном уровне уловить семантический смысл операции сложения над векторами: если к субъекту прибавить отношение, то результат будет примерно равен объекту.
- Основным недостатком модели TransE является описание отношений один-ко-многим и много-ко-многим. Например, если у триплетов совпадают значения субъекта или объекта, то в этом случае будут сгенерированы почти совпадающие эмбединги.




Модель TransR (TDM)

- Модель очень похожа на TransE, но позволяет преодолеть недостатки описания отношений один-ко-многим и много-ко-многим. Для этого модель использует два пространства, одно для встраивания сущностей, а второе для встраивания отношений. При этом, у сущности будут различные проекции на пространство отношений в зависимости от того, в каких отношениях используется данная сущность.
- Основной недостаток модели TransR состоит в том, что из-за необходимости вычисления проекционной матрицы для каждого отношения, модель теряет простоту и эффективность TransE. Обучение модели TransR займет больше времени и ресурсов чем обучение модели TransE.




Модель RESCAL (SMM)

- Модель ассоциирует каждую сущность с вектором и старается передать скрытые смыслы (факторы) этой сущности. Каждое отношение представлено в виде матрицы, которая моделирует попарные взаимодействия скрытых факторов.
- К недостаткам модели можно отнести ее вычислительную сложность, связанную с большой размерностью матрицы отношений **M_r** .




Модель DistMult (SMM)

- Упрощает модель RESCAL, накладывая ограничение на матрицу отношений. В DistMult матрица отношений обязательно должна быть диагональной для каждого отношения r .
- Функция правдоподобия отражает попарные взаимодействия только между компонентами сущностей, лежащими в одинаковых измерениях. За счет этого сложность модели становится линейной, а не квадратичной. Однако эта модель слишком сильно упрощена и может работать только с симметричными отношениями. Этого явно недостаточно для абстрактного графа знаний, в котором отношения могут быть произвольными.



Модель HoIE (SMM)

- Модель голографического эмбединга. Она совмещает в себе мощность RESCAL и простоту DistMult. В HoIE к представлениям сущностей сначала применяется оператор взаимной корреляции. После этого, для определения значения функции правдоподобия, полученный вектор совмещается с вектором представления СВЯЗИ.
- Взаимная корреляция сжимает попарные взаимодействия компонентов сущностей. Поэтому сложность у модели линейная, что эффективнее, чем у RESCAL. Но при этом, модель HoIE может работать с асимметричными отношениями, так как взаимная корреляция не коммутативна. Эта особенность недоступна в модели DistMult.



Векторное представление гиперграфа – 1

- [Статья Hyperedge2vec: Distributed Representations for Hyperedges](#)





Figure 1: Example illustrating “set-like” hypergraph structure from two domains. Left is a collaboration network between four individuals and on right is a network resulting from two sentences: “He is a good boy” & “She is a good girl”; and eight word nodes.

Векторное представление гиперграфа – 2

- Структура гиперребер может быть представлена в виде диаграммы Хассе.



Векторное представление гиперграфа – 3




Figure 3: For the given hypergraph between four nodes (A,B,C,D) we consider the complete *hasse* lattice. For a given hyperedge {B,C} (square box) we then construct the sub-lattice made of hyperedges with distance $h = 2$ from {B,C}. We perform random walk (with $\tau = 0.2$) starting from the node corresponding to hyperedge {B,C} and sample $p = 3$ hyperedges (nodes visited by the random walk; shown with a check-mark ✓). Finally, we train the autoencoder to reconstruct the original hyperedge from these p noisy hyperedges.

Графовые нейронные сети (GNN)

- [Обзорная статья профессора А.Г. Дьяконова](#)
- [Общие принципы работы GNN](#)
- [Статья с примерами кода «What Are Graph Neural Networks? How GNNs Work, Explained with Examples»](#)
- [Серия статей «Graph Representation Learning»](#)
- Graph Convolutional Network (GCN)
 - [Краткая статья «Graph Convolutional Networks – Deep Learning on Graphs»](#)
 - [Детальная статья «Graph convolutional networks: a comprehensive review»](#)
- Graph Attention Network (GAT)
 - [Статья Understanding Graph Attention Networks \(GAT\)](#)
- Графовые трансформеры
 - [Статья с пояснением](#)
 - [Оригинальная статья](#)

Гиперграфовые нейронные сети – 1

- [Статья «Hypergraph Neural Networks»](#)





Figure 1: Examples of complex connections on social media data. Each color point represents a tweet or microblog, and there could be visual connections, text connections and social connections among them.

Гиперграфовые нейронные сети – 2



1. Мультимодальный набор данных делится на обучающие и тестовые выборки, каждая выборка содержит набор вершин с их признаками.
2. Далее на основе выборок (с учетом их корреляции) генерируются группы гиперребер.
3. Группы гиперребер объединяются, чтобы сформировать общую матрицу смежности гиперграфа.
4. Матрица смежности и признаки вершин подаются на вход HGNN-сети, на выходе сети формируются метки выходных вершин.

Гиперграфовые нейронные сети – 3

HGNN-сеть использует сверточные слои:





Figure 4: The illustration of the hyperedge convolution layer.

Области применения графов знаний


Источник: <https://iopscience.iop.org/article/10.1088/1742-6596/1487/1/012016>



Вопросно-ответные системы


- Источник:
<https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/sfw2.12028>
- Для создания вопросно-ответных систем на основе графов знаний существует четыре основных подхода:
 1. Семантический разбор (semantic parsing)
 2. Сравнение подграфов (subgraph matching)
 3. Использование шаблонов (template-based question answering)
 4. Использование баз знаний (question answering over knowledge bases)

Семантический разбор




- Идея состоит в том, чтобы применить несколько преобразований данных из вопроса на ЕЯ к логической форме или формальному запросу.
- Для этого используются методы обработки естественного языка (NLP), такие как токенизация, распознавание именованных сущностей (NER), частеречная разметка (POS), анализ зависимостей и связывание сущностей (EL).
- Финальные шаги включают генерацию запроса и генерацию ответа.

Сравнение подграфов




- В качестве альтернативы использованию семантического разбора может быть применено сравнение подграфов, так как выполнение формального запроса эквивалентно поиску подграфа.

Использование шаблонов



- Шаблон представляет собой заготовку запроса с определенной степенью сложности, которая соответствует базе знаний, и содержит слоты, заполняемые информацией из сущностей и отношений. Качество системы значительно зависит от усилий, затраченных на создание шаблонов. Ранее создание шаблонов в основном осуществлялось с помощью ручных аннотаций; в последнее время появились автоматические подходы.
- Использование данного подхода предполагает наличие оффлайн и онлайн этапов.
- На оффлайн этапе создаются шаблоны. На основе пар вопрос-ответ формируются шаблоны вопроса и запроса для заполнения слотов.
- Онлайн этап включает сопоставление вопроса с шаблоном вопроса. Производится поиск шаблона запроса и заполнение слотов.


Использование баз знаний



- End-to-end решения выполняют преобразование sequence-to-sequence или применяют методы для извлечения данных непосредственно из базы знаний.
- Выбор окончательного ответа основан на представлениях вопросов на ЕЯ, полученных с применением методов машинного обучения.
- После извлечения ответов-кандидатов из базы знаний их применимость оценивается по заранее заданной шкале с помощью специализированной функции оценки.


Комбинирование с языковыми моделями

- Источник: <https://arxiv.org/abs/2012.04808>



Q: Where would you find magazines alongside many other printed works?

C: Bookstore



Ques_ent: magazines

Choice_ent: bookstore

Rel: magazines, AtLocation, Bookstore



magazines: A non-academic periodical publication

bookstore: A store where books are bought and sold.

Figure 1: In our model, the input to ALBERT includes the question, choice, entity names, description text and triple. An attention-based weighted sum and a softmax layer process the output from ALBERT to produce the prediction.

Рекомендательные системы

- Источник: <https://www.mdpi.com/2078-2489/12/6/232/pdf>
- Граф знаний может выступать в роли онтологии, на основе которой выдаются фиксированные рекомендации пользователю на основе текущих выбранных элементов (если покупается книга, то рекомендуется подставка для книг).
- Граф знаний в форме векторного представления может быть использован как в подходе на основе содержания, так и при коллаборативной фильтрации.
- Подход на основе гетерогенных информационных сетей предполагает, что база знаний представляется в виде мета-графов.
- С использованием подхода на основе LSTM-сети можно осуществлять эффективный поиск в мета-графах, что может служить основой для выбора рекомендаций.

Гетерогенная информационная сеть

- Heterogeneous Information Networks (HIN).




Figure 1: Example of HIN, which is built based on the web page for Royal House on Yelp.






Figure 2: Example of HIN Schema. A: aspect extracted from reviews; R: reviews; U: users; B: business; Cat: category of item; Ci: city.

Пример мета-графов



(a) Yelp-200K (Star: the average stars a business obtained).




(b) Amazon-200K (Brd: brand of the item).

Figure 3: Meta-graphs used for Amazon and Yelp datasets.


Knowledge Graph Completion – 1

- Источник: <https://www.semanticscholar.org/paper/Knowledge-Graph-Completion%3A-A-Review-Chen-Wang/b770eaea1124b5f5805713428daf023c792b15cd>
- Подход 1. Основывается на векторных представлениях.



Knowledge Graph Completion – 2

- ИСТОЧНИК:
<https://openreview.net/pdf?id=wHAe6eoT8>
- Подход 2. Основывается на предобученных языковых моделях.



Type	Template
Definition	"[<i>Entity</i>]: [<i>Definition Text</i>]."
Attribute	"The [<i>Attribute</i>] of [<i>Entity</i>] is [<i>Value</i>]."

Table 1: Templates for support information, where [*Entity*], [*Attribute*], [*Value*] denote the label of entity, attribute and value respectively. [*Definition Text*] is the text corresponding to the entity definition.

Commonsense reasoning – 1



Figure 8: A snapshot of commonsense knowledge relationships in ATOMIC₂₀²⁰. Gray nodes represent events. Red, purple and green nodes represent social-interaction commonsense, event-centered commonsense, and physical-entity commonsense, respectively. Rest of the colors represent intersection of the categories.

Commonsense reasoning – 2

- Источник: <https://arxiv.org/abs/2012.111490>





Fig. 1. Snippet of CSKG for the example task of section 1. CSKG combines: 1) lexical nodes (`piano`, `keys`, `music`; in blue), 2) synsets like `piano (artifact)`, `seat (dramaturgy)` (in green), and 3) frames (`fn:noise_makers`) and frame elements (`fn:fe:use`) (in purple). The link between `piano` and `piano (artifact)` is missing, but trivial to infer.

Commonsense reasoning – 3

- Источник: <https://arxiv.org/abs/2011.00766>



Bayesian Reasoning Framework

- Источник: <https://ojs.aaai.org/index.php/AAAI/article/view/16565>





Figure 1: An illustrated toy example which generated from randomized two-dimensional Gaussian distribution for representing entities and relations in a partial KG. The mean of an entity indicates its position, and the variance indicates uncertainty.

GraphRAG



- RAG works on text and images, which can be uniformly formatted as 1D sequences or 2D grids with no relational information.
- In contrast, GraphRAG works on graph-structured data, which encompasses diverse formats and includes domain-specific relational information.

Heterogeneous Graph Neural Networks

Definition 1 Heterogeneous graphs. A heterogeneous graph is defined as $G = \{V, E, \mathcal{T}^v, \mathcal{T}^e\}$, where V is the set of nodes with a node type mapping function $\phi : V \rightarrow \mathcal{T}^v$, and E is the set of edges with an edge type mapping function $\psi : E \rightarrow \mathcal{T}^e$. Each node $v_i \in V$ is attached with a node type $c_i = \phi(v_i) \in \mathcal{T}^v$. Each edge $e_{t \leftarrow s} \in E$ (e_{ts} for short) is attached with a relation $r_{c_t \leftarrow c_s} = \psi(e_{ts}) \in \mathcal{T}^e$ ($r_{c_t c_s}$ for short), pointing from the source node s to the target node t . When $|\mathcal{T}^v| = |\mathcal{T}^e| = 1$, the graph degenerates into homogeneous.

The graph structure of G can be represented by a series of adjacency matrices $\{A_r : r \in \mathcal{T}^e\}$. For each relation $r_{c_t c_s} \in \mathcal{T}^e$, $A_{c_t c_s} \in \mathbb{R}^{|V^{c_t}| \times |V^{c_s}|}$ is the corresponding adjacency matrix where the nonzero values indicate positions of edges $E^{c_t c_s}$ of the current relation.

Definition 2 Metapaths. A metapath defines a composite relation of several edge types, represented as $\mathcal{P} \triangleq c_1 \leftarrow c_2 \leftarrow \dots \leftarrow c_l$ ($\mathcal{P} = c_1 c_2 \dots c_l$ for short).

